UNIVERSIDAD ANDRÉS BELLO

Magíster en Ciencia de Datos e Inteligencia Artificial

MCDI501 Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis exploratorio e inferencial de entregas atrasadas en comercio electrónico

Grupo 1

José Ignacio Rodríguez
Yerko G. Gallardo Miranda
Sebastián Rojas Araya

Dataset: *E-Commerce Shipping Data*, versión 1
Octubre de 2026

Problema de decisión. Identificar características y segmentos de envíos que ameriten una investigación operacional posterior. Se caracteriza una base de 10.999 registros, se estiman cuatro parámetros y se presentan siete contrastes con control de multiplicidad. Las asociaciones no permiten atribuir causas ni generalizar automáticamente a una población externa.

https://github.com/joserodriguezc/grupo_1_estadistica_computacional

Informe técnico grupal | Ponderación: 20%

1 Preparación y carga de datos

Contexto y pregunta. Según Gopalani (2021), la base reúne envíos de una empresa de comercio electrónico de productos electrónicos. Se pregunta: *¿qué características se asocian con el atraso y qué evidencia orienta una revisión operacional?* La empresa, el período y el marco muestral no están documentados. La unidad provisional es el registro de envío asociado a un cliente; un ID único no garantiza independencia ni un cliente por fila.

El CSV contiene **10.999 filas y 12 columnas**. Se carga con `pandas.read_csv(encoding='utf-8-sig')` y se conserva intacto, con SHA-256 documentado. La copia del repositorio conserva los valores del original de Kaggle, con saltos LF en vez de CRLF. Se crean nombres analíticos y el alias `entrega_atrasada`: **1 = atrasada; 0 = puntual**.

Tabla 1: Clasificación estadística y papel de las doce variables.

Variable original	Tipo estadístico	Unidad o categorías
`ID`	Identificador nominal	Control de unicidad
`Warehouse_block`	Cualitativa nominal	A, B, C, D, F
`Mode_of_Shipment`	Cualitativa nominal	Flight, Road, Ship
`Customer_care_calls`	Cuantitativa discreta	Número de llamadas
`Customer_rating`	Cualitativa ordinal	Escala 1–5
`Cost_of_the_Product`	Cuantitativa de razón	USD, según fuente
`Prior_purchases`	Cuantitativa discreta	Compras previas
`Product_importance`	Cualitativa ordinal	low < medium < high
`Gender`	Cualitativa nominal	F, M
`Discount_offered`	Cuantitativa	Unidad no documentada
`Weight_in_gms`	Cuantitativa de razón	Gramos
`Reached.on.Time_Y.N`	Nominal binaria	0 puntual; 1 atrasada

Calidad y tratamiento. Cero nulos, cero duplicados con y sin ID y 10.999 ID distintos; se conservan todas las filas. Los extremos por IQR en compras previas (1.003) y descuento (2.209) se mantienen porque no son errores acreditados. Se verifican dominios, tipos y sumas de frecuencias. No se imputan ni se fabrican faltantes. La bodega F se mantiene pese a que la descripción enumera A–E. El descuento no se interpreta como porcentaje o moneda; ID no se usa en correlaciones.

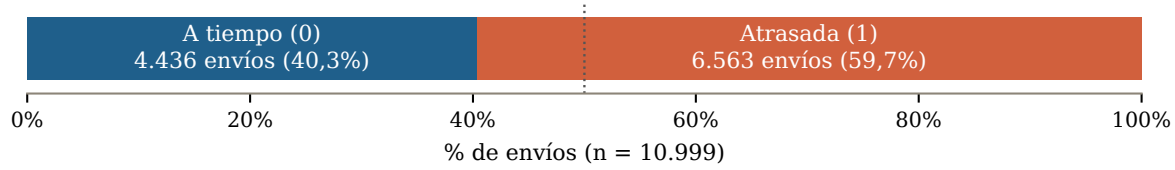


Figura 1: El atraso afecta al 59,67% de los registros, frente a 40,33% puntuales.

La Figura 1 muestra 6.563 atrasos y 4.436 puntuales. Dimensiona el problema en el archivo, sin establecer un indicador general del comercio electrónico.

2 Análisis exploratorio de datos

2.1 Centro, dispersión y forma

Tabla 2: Resumen de cuantitativas; n = 10.999 por variable. A: asimetría ajustada; K: exceso de curtosis de Fisher.

Variable	Media	Mediana	DE	Q1	Q3	A	K
Llamadas	4,05	4,00	1,14	3,00	5,00	0,39	-0,31
Costo (USD)	210,20	214,00	48,06	169,00	251,00	-0,16	-0,97
Compras previas	3,57	3,00	1,52	3,00	4,00	1,68	4,01
Descuento (u. orig.)	13,37	7,00	16,21	4,00	10,00	1,80	2,00
Peso (g)	3.634,02	4.149,00	1.635,38	1.839,50	5.050,00	-0,25	-1,45

La Tabla 2 calcula la forma con `stats.skew(bias=False)` y `stats.kurtosis(fisher=True,bias=False)` (SciPy, s. f.). La referencia normal tiene A = K = 0; el exceso no es la curtosis de Pearson. Descuento y compras previas tienen asimetría positiva de **1,80 y 1,68**, y exceso de **2,00 y 4,01**: sus valores altos tienen mayor influencia relativa en los momentos. La media del descuento (13,37) supera su mediana (7).

El peso tiene A = $-$**0,25** y K = $-$**1,45**, pero el histograma evidencia bimodalidad. Los coeficientes no prueban normalidad; ni media ni mediana describen por sí solas los dos grupos de valores. El IQR del peso es **3.210,50 g** y su DE **1.635,38 g**. Mínimos, máximos e IQR completos se exportan en el notebook.

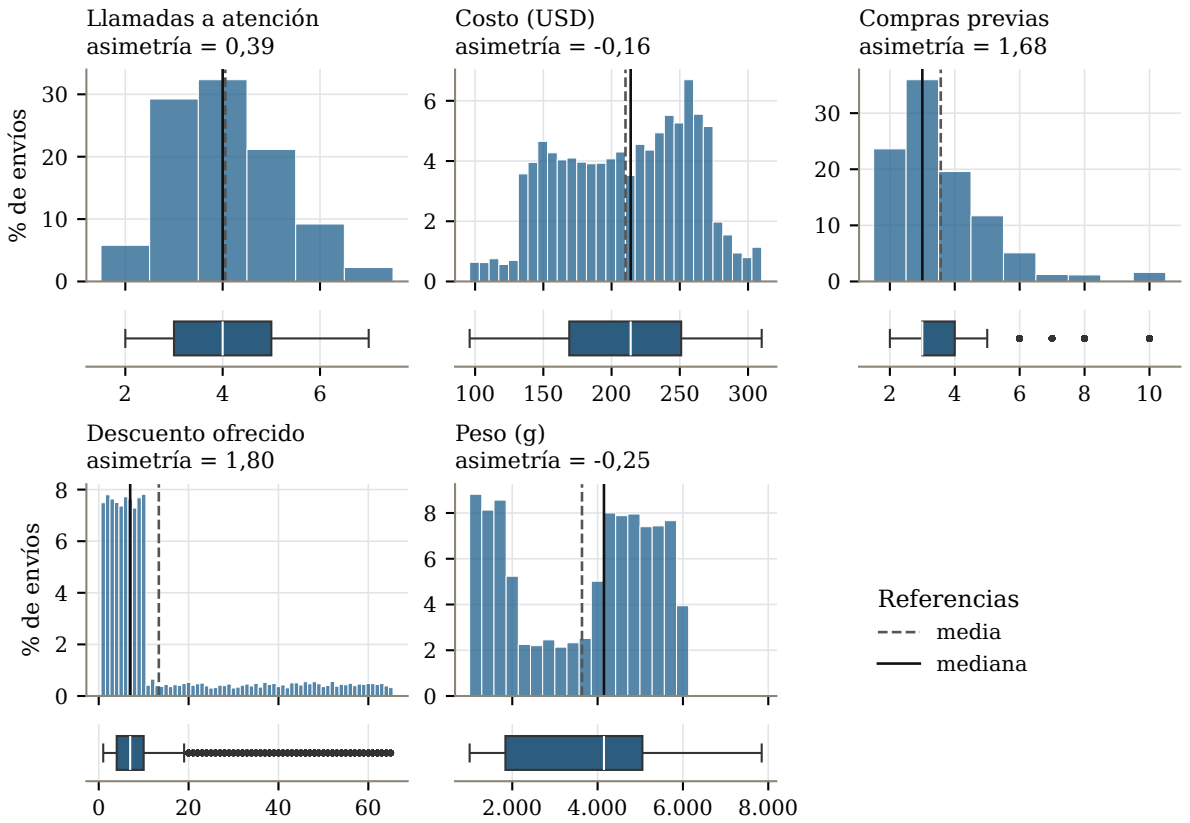


Figura 2: Descuento y compras previas presentan colas derechas; el peso tiene dos grupos de concentración. Histogramas y cajas conservan todos los valores.

La Figura 2 respalda la forma de la Tabla 2. Las líneas distinguen media y mediana; no se eliminan extremos para mejorar la apariencia. Llamadas son conteos; calificación e importancia son ordinales y se describen con frecuencias ordenadas, sin distancias iguales entre categorías.

2.2 Categorías y relaciones bivariadas

La modalidad marítima concentra **7.462 registros (67,84%)**, aérea 1.777 (16,16%) y terrestre 1.760 (16,00%). La bodega F reúne 3.666 registros y cada otra bodega 1.833–1.834. La mediana de calificación es 3 (Q1 = 2; Q3 = 4). Estos volúmenes no son tasas de atraso.

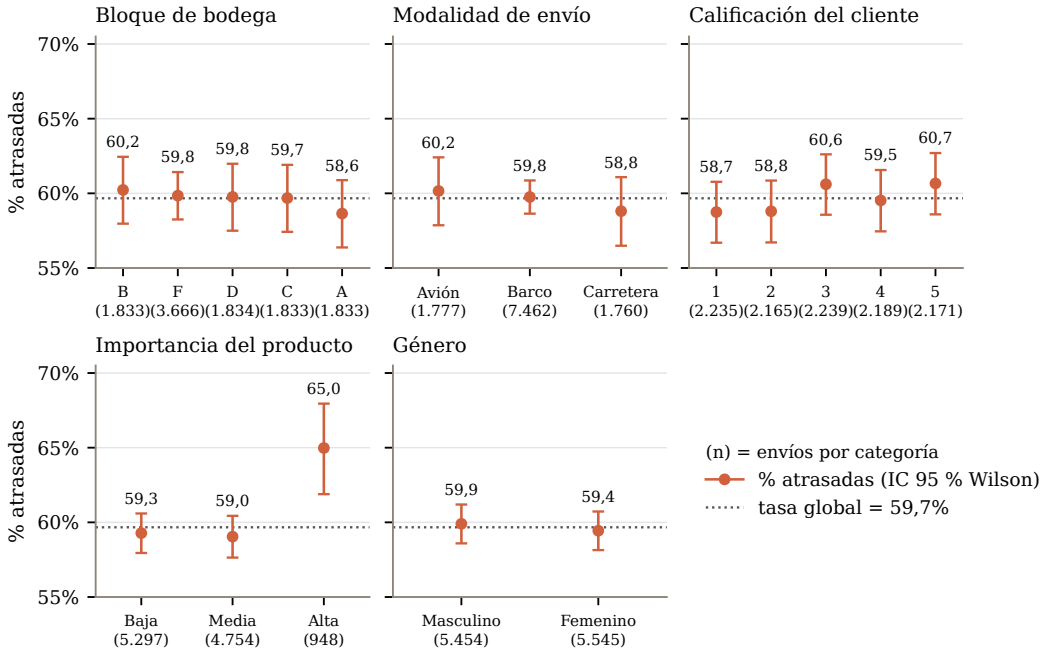


Figura 3: La importancia alta registra 64,98% de atraso; las diferencias por modalidad y bodega son reducidas. Tasas por categoría con IC individuales de Wilson y n.

En la Figura 3, importancia alta supera la tasa global de 59,67%; su V de Cramér frente al resultado es **0,0333**. Modalidad tiene V = **0,0082** y bodega V = **0,0100**. Superposición de IC no equivale a una prueba; E2 contrasta importancia y T01 modalidad.

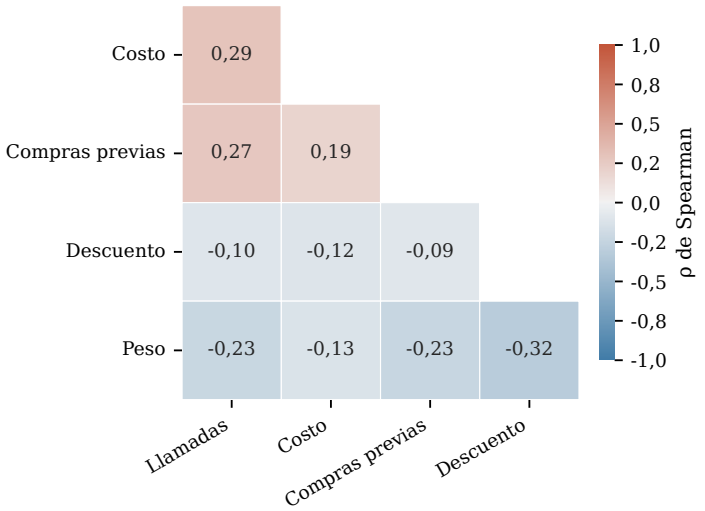


Figura 4: Peso y descuento presentan la mayor asociación monótona entre cuantitativas: $\rho = -0{,}316$.

La Figura 4 usa Spearman para explorar relaciones monótonas mediante rangos. Peso–descuento tiene $\rho = -0{,}316$; llamadas–costo, $\rho = 0{,}294$; llamadas–compras previas, $\rho = 0{,}273$; costo–compras previas, $\rho = 0{,}194$. Las magnitudes bivariadas son limitadas, sin demostrar independencia conjunta ni ausencia de confusión. La matriz completa se exporta y excluye ID y resultado binario.

3 Estimación de parámetros

Se estiman **tres medias relevantes y una proporción**. Se conserva la aproximación normal de la guía: $\bar{x} \pm z_{0,975} s/\sqrt{n}$ y $\hat{p} \pm z_{0,975}\sqrt{\hat{p}(1-\hat{p})/n}$, con $z_{0,975} = 1{,}95996$. Se revisan tamaño, forma, extremos e influencia. En la proporción, $n\hat{p} = 6.563$ y $n(1-\hat{p}) = 4.436$, mayores que 10. La independencia es un supuesto de diseño no verificable con estas columnas.

Tabla 3: Estimaciones e IC individuales del 95%, con n efectivo.

Parámetro	n	Estimación	Inferior	Superior
Proporción de atraso	10.999	0,59669	0,58752	0,60586
Peso medio (g)	10.999	3.634,02	3.603,45	3.664,58
Costo medio (USD)	10.999	210,20	209,30	211,10
Llamadas medias	10.999	4,054	4,033	4,076

Sentido del 95%. Caracteriza la cobertura del *procedimiento*: bajo muestreo repetido y los supuestos del método, aproximadamente el 95% de los intervalos construidos contendría el parámetro poblacional fijo. Para un intervalo calculado, no significa que el parámetro tenga 95% de probabilidad de estar dentro, ni que el 95% de los envíos quede en ese rango.

La Tabla 3 estima un atraso de 59,67%, con intervalo 58,75–60,59%; peso medio de 3.634,02 g, costo de USD 210,20 y llamadas de 4,054. El ancho relativo va de 0,85% a 3,07%. La precisión no corrige selección, dependencia ni incertidumbre del origen. Para tasas por categoría se usa Wilson, que no colapsa en 0 o 1; las diferencias de medias usan IC t de Welch. No se presentan IC simultáneos.

4 Pruebas de hipótesis

Se utiliza $\alpha = 0{,}05$ como tolerancia convencional al error tipo I y Holm (1979) para una familia de siete pruebas. Las comparaciones son bilaterales; χ^2 contrasta independencia. El plan inicial incluyó modalidad, peso y costo. Durante el EDA se añadió descuento y se reorganizó T03; ese cambio y los contrastes complementarios son **exploratorios**, sin atribuirles preespecificación. Holm no corrige selección de hipótesis o umbrales a partir del EDA.

4.1 T01 Modalidad y atraso

H_0: modalidad y resultado independientes; H_1: asociación. Se emplea `stats.chi2_contingency`. Cada envío ocupa una celda y se requiere independencia entre registros.

Tabla 4: Frecuencias observadas para el contraste de independencia.

Modalidad	Puntual	Atrasada	Total
Flight	708	1.069	1.777
Road	725	1.035	1.760
Ship	3.003	4.459	7.462
Total	4.436	6.563	10.999

La Tabla 4 produce $\chi^2(2) = 0{,}7434$, $p = 0{,}68955$ y V = 0,00822. La mínima frecuencia esperada es 709,82, superior a 5. No se rechaza H_0 con Holm; no hay evidencia suficiente de asociación, lo que no demuestra independencia perfecta.

4.2 T02 Peso medio por resultado

$H_0 : \mu_{atr} - \mu_{punt} = 0$; $H_1 : \mu_{atr} - \mu_{punt} \neq 0$. Welch no impone igualdad de varianzas. Se revisan distribuciones, tamaños e influencia de extremos; independencia y comparabilidad siguen siendo supuestos.

Con **6.563 atrasadas y 4.436 puntuales**, las medias son **3.272,64 g y 4.168,67 g**. Diferencia atrasadas menos puntuales: −896,03 g, IC 95% [−956,03; −836,03]; $t = -29{,}27$, gl = 9 526,57 y $p = 1{,}93 \times 10^{-180}$. El efecto $d_{av} = -0{,}569$ divide la diferencia por la raíz de la media de las dos varianzas muestrales. Se rechaza H_0 tras Holm, sin inferir causas.

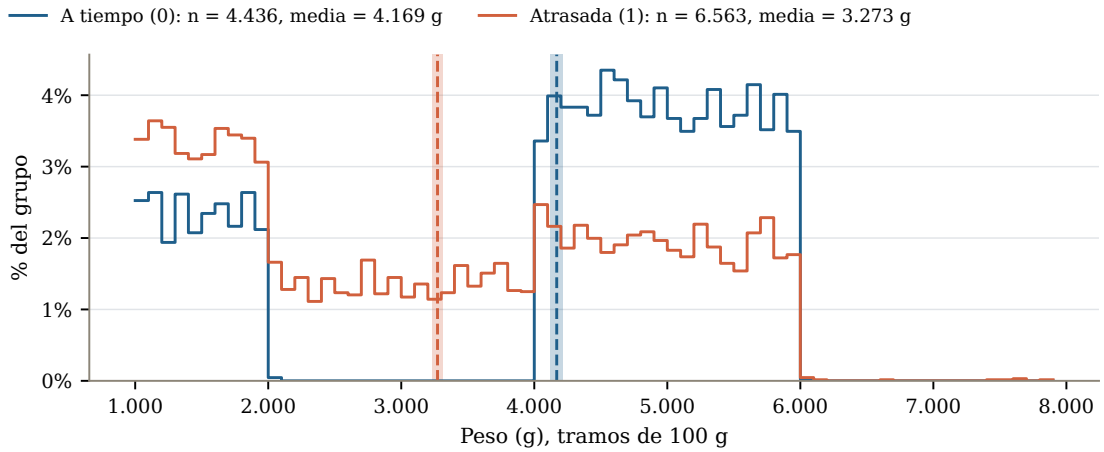


Figura 5: El peso medio es 896,03 g menor entre atrasadas; en (2.000, 4.000] g hay 1.787 atrasadas y una puntual.

La Figura 5 muestra diferencias de forma; E1 complementa la comparación de medias mediante rangos. La franja con una puntual no tiene separación completa.

4.3 T03 Descuento medio por resultado

$H_0 : \mu_{atr} - \mu_{punt} = 0$; $H_1 : \mu_{atr} - \mu_{punt} \neq 0$. Welch se utiliza por la diferencia de dispersión: DE = 19,11 en atrasadas y 2,88 en puntuales, con los mismos tamaños de T02.

Las medias son **18,66 y 5,55 unidades originales**; diferencia 13,12, IC 95% [12,65; 13,59], $t = 54{,}70$, gl = 6 998,09 y $d_{av} = 0{,}960$. La implementación devuelve p = 0 por subdesbordamiento: no es probabilidad matemática nula. Se rechaza H_0 tras Holm. El descuento no se expresa como porcentaje ni dinero.

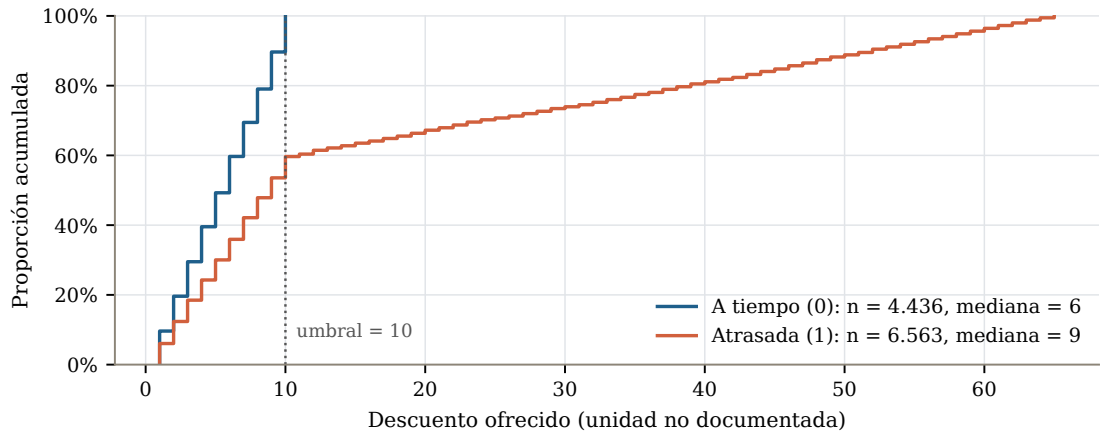


Figura 6: Ningún envío puntual registra descuento mayor que 10; el segmento comprende 2.647 registros atrasados.

La Figura 6 motiva revisar origen y temporalidad del descuento, sin concluir que causa el atraso.

4.4 Contrastes complementarios y multiplicidad

E1, rangos del peso. H_0: distribuciones iguales; H_1: diferencia detectable por rangos. Mann–Whitney asintótico corrige empates y continuidad: $U = 10\,000\,332{,}5$, $p = 3{,}40 \times 10^{-171}$ y efecto biserial de rangos $r = -0{,}313$. Se rechaza H_0; sin igualdad de formas no es una prueba exclusiva de medianas.

E2, importancia alta. $H_0 : p_{alta} = p_{resto}$; $H_1 : p_{alta} \neq p_{resto}$. La prueba z usa proporción combinada bajo H_0; los conteos esperados son suficientes. Hay **64,98% de atraso en 948 productos de importancia alta**, frente a **59,17% en 10.051 del resto**. Diferencia 5,81 puntos porcentuales (pp), IC normal individual [2,63; 9,00] pp; $z = 3{,}486$ y $p = 0{,}000490$. Se rechaza H_0 con Holm, sin identificar causas.

E3, descuento mayor que 10. $H_0 : p_{>10} = p_{\leq 10}$; $H_1 : p_{>10} \neq p_{\leq 10}$. La prueba z combinada tiene conteos esperados bajo H_0 mayores que 10: $z = 48{,}54$; p no representable como número positivo en la exportación. Se observa **100% de atraso en 2.647 registros**, frente a **46,89% en 8.352** con descuento ≤ 10. Diferencia 53,11 pp; riesgo relativo descriptivo 2,13. El umbral proviene del EDA y exige validación independiente.

El IC de Wilson del grupo > 10 es **[99,86%; 100%]**, no [100%; 100%]. El IC normal de la diferencia exportado [52,04; 54,18] pp no incorpora varianza estimada del grupo con proporción 1 y se lee con cautela; para ese segmento se prioriza Wilson. No se asume tasa poblacional exactamente igual a 1.

E4, costo medio. $H_0 : \Delta_{costo} = 0$; $H_1 : \Delta_{costo} \neq 0$. Welch compara USD 207,29 y USD 214,50; diferencia $-7{,}21$ USD, IC 95% $[-9{,}03; -5{,}39]$ y $d_{av} = -0{,}150$. Se rechaza H_0 con Holm, pero el efecto es menor que para peso y descuento.

Tabla 5: Una familia de siete pruebas, Holm y $\alpha = 0{,}05$.

Contraste	p original	p Holm	Decisión
T01 Modalidad	0,68955	0,68955	No rechazar
T02 Peso (Welch)	$1{,}93 \cdot 10^{-180}$	$9{,}65 \cdot 10^{-180}$	Rechazar
T03 Descuento (Welch)	No repr.	No repr.	Rechazar
E1 Peso (rangos)	$3{,}40 \cdot 10^{-171}$	$1{,}36 \cdot 10^{-170}$	Rechazar
E2 Importancia alta	0,000490	0,000980	Rechazar
E3 Descuento > 10	No repr.	No repr.	Rechazar
E4 Costo (Welch)	$1{,}04 \cdot 10^{-14}$	$3{,}11 \cdot 10^{-14}$	Rechazar

"No repr." indica subdesbordamiento; se conserva el cero de máquina en CSV sin inventar una cota numérica. La Tabla 5 controla multiplicidad de la familia, no vuelve confirmatoria la exploración. No rechazar H_0 no demuestra igualdad; significancia no implica importancia operacional.

5 Interpretación y avance del proyecto

El atraso de **59,67%** justifica investigar el proceso que originó los registros. Modalidad tiene V = **0,0082** y p Holm = **0,68955**; no respalda cambiar de transporte. El peso es **3.272,64 frente a 4.168,67 g**, y descuento **18,66 frente a 5,55**: asociaciones que requieren explicar composición, temporalidad y registro antes de intervenir sobre carga o política comercial.

Recomendación concreta. Auditar los **2.647 envíos con descuento > 10**, todos atrasados: verificar cómo se otorgó, si se registró antes o después de la entrega, campañas, productos, fechas, bodegas y rutas. Comparar con los **8.352 de descuento** ≤ 10, cuyo atraso es 46,89%, y revisar la franja (2.000, 4.000] g. Confirmar el patrón en otro período independiente; el umbral es señal exploratoria, no regla operacional validada.

Limitaciones. Origen muestral y período desconocidos; posible dependencia; confusión no controlada; descuento sin unidad y bodega F discrepante; llamadas y calificaciones potencialmente posteriores al resultado; selección de hipótesis y umbral durante EDA. Ningún p pequeño o IC estrecho elimina estas limitaciones. Los siguientes pasos priorizan procedencia, temporalidad y validación fuera de estos registros.

6 Notebook y repositorio reproducibles

`sumativa_1/` contiene datos, documentación, notebook, salidas y LaTeX. El notebook se ejecutó en sesión nueva y conserva el SHA-256 del CSV. `outputs/tablas/entorno_ejecucion.json` registra Python y versiones utilizadas; `pyproject.toml` y `uv.lock` fijan el entorno del equipo. El README detalla rutas y comandos.

Procedimientos (Virtanen et al., 2020; SciPy, s. f.; statsmodels, s. f.):

- Carga y controles: `pandas.read_csv`, `isna`, `duplicated`, `nunique`, `crosstab`.
- Descriptiva y correlación: `DataFrame.describe`, `stats.skew`, `stats.kurtosis`, `DataFrame.corr(method='spearman')`.
- IC: `stats.norm.ppf`; DE con `ddof=1`; `proportion_confint(method='wilson')` para tasas por grupo.
- Contrastes: `stats.chi2_contingency`, `stats.ttest_ind(equal_var=False)`, `confidence_interval(0.95)`, `stats.mannwhitneyu(method='asymptotic')`.
- Proporciones: z manual combinado y `stats.norm.sf`; IC de diferencia no combinado. Holm: `multipletests(method='holm')`; Cramér: `stats.contingency.association`.

Las tablas proceden de exportaciones, no de imágenes. No se usa simulación ni muestreo aleatorio, por lo que no corresponde semilla. Las salidas pueden regenerarse; la Formativa 1 se conserva como entrega histórica.

Referencias

Gopalani, P. (2021). *E-Commerce Shipping Data* (versión 1) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/prachi13/customer-analytics

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... Vázquez-Baeza, Y. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*, 261–272. https://doi.org/10.1038/s41592-019-0686-2

SciPy. (s. f.). *Statistical functions (scipy.stats)* [Documentación]. https://docs.scipy.org/doc/scipy/reference/stats.html

statsmodels. (s. f.). *Statistical tests and tools* [Documentación]. https://www.statsmodels.org/stable/stats.html