

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, Simulación y Métodos de Remuestreo

Informe técnico grupal · 20 %

Título del proyecto:	Validación de los factores asociados al atraso en envíos de comercio electrónico
Integrantes:	José Ignacio Rodríguez, Yerko Gallardo Miranda y Sebastián Rojas Araya
Dataset:	*E-Commerce Shipping Data* (Gopalani, 2021), 10.999 envíos
Docente:	J. P. Maidana
Fecha:	21/10/2026
Repositorio GitHub:	`https://github.com/joserodriguezc/grupo_1_estadistica_computacional`

Problema, conexión con S1 y diseño computacional

La Sumativa 1 (S1) preguntó *qué características se asocian con el atraso y qué evidencia orienta una revisión operacional*. Sobre 10.999 envíos (6.563 atrasados, 59,67 %), estimó cuatro parámetros, contrastó siete hipótesis con control de Holm y recomendó auditar los 2.647 envíos con descuento mayor que 10, todos atrasados. Esta evaluación (S2) valida esos resultados **propios de S1** con remuestreo y simulación. Para cada uno pregunta si se sostiene sin los supuestos de normalidad, sin envíos individuales o extremos, y con otra composición de la muestra.

Datos y reproducibilidad. Los datos se leen desde el CSV original de S1 (`sumativa_1/data/raw/`), con huella SHA-256 verificada, y las cifras de referencia, desde las tablas exportadas de S1. La semilla `1505514103` proviene del pulso 1.053.589 del faro de aleatoriedad de la Universidad de Chile, registrado antes de su publicación. Con `SeedSequence(SEMILLA).spawn(7)` se derivan siete flujos independientes, uno por técnica, de modo que reejecutar una sección no altera las demás. Todas las técnicas usan $B = 10.000$ réplicas.

Alcance. El cuerpo desarrolla los resultados que sostienen la conclusión de S1. El notebook de validación completa aplica las mismas técnicas a los **194 resultados** del inventario de S1. Los anexos presentan las siete pruebas, las correlaciones y asociaciones, y la matriz de resultados validados. Remuestrear supone envíos independientes e idénticamente distribuidos, igual que S1, y no corrige sesgos de selección ni permite conclusiones causales.

1. Validación de resultados de S1 mediante bootstrap

S1 usó el IC de Wilson para la proporción de atraso y el IC t para las medias, aunque el peso es bimodal y el costo no es normal. Se validan los cuatro parámetros de S1 y la diferencia de peso medio, el efecto central de S1. El *bootstrap* no paramétrico (Efron y Tibshirani, 1993) remuestrea con reemplazo los 10.999 envíos. En la diferencia se remuestrea dentro de cada grupo, conservando 6.563 atrasados y 4.436 puntuales. Se calculan IC percentil y BCa al 95 %; este último corrige el sesgo (z_0, con empates) y la asimetría (aceleración a por *jackknife*) (Efron, 1987). El BCa propio coincide con `scipy.stats.bootstrap` sobre las mismas réplicas (tolerancia relativa 10^{-10}).

Tabla 1: IC al 95 % de S1 frente a los IC *bootstrap* ($B = 10.000$).

Estimando	IC de S1	IC percentil	IC BCa	Ancho BCa/S1	EE boot./S1
Atraso (%)	Wilson [58,75; 60,58]	[58,74; 60,58]	[58,75; 60,59]	1,002	0,999
Peso medio (g)	t [3.603,5; 3.664,6]	[3.602,0; 3.664,7]	[3.602,8; 3.665,3]	1,023	1,011
Costo medio (USD)	t [209,30; 211,10]	[209,29; 211,09]	[209,31; 211,11]	1,002	0,994
Llamadas medias	t [4,033; 4,076]	[4,034; 4,075]	[4,034; 4,076]	0,978	0,988
Dif. de peso (g)	Welch [−956,0; −836,0]	[−955,5; −836,6]	[−955,4; −836,5]	0,991	0,999

Los IC de S1 se confirman (tabla 1 y figura 1). Los anchos difieren a lo sumo un 2,3 %, el centro del BCa se desplaza como máximo 0,04 errores estándar (EE) y el EE *bootstrap* difiere del analítico en menos de 1,3 %. **No hay discrepancias, y la razón es clara**: las distribuciones *bootstrap* son simétricas (asimetría entre −0,04 y 0,005), por lo que $|z_0| \leq 0{,}027$ y $|a| \leq 0{,}0011$, y el BCa casi coincide con el percentil. Aunque el peso es bimodal, con 10.999 envíos (4.436 en el grupo menor) el teorema central del límite normaliza la media, así que los supuestos de forma de S1 no comprometían sus IC.

Confiabilidad de cada método. El IC t es exacto bajo normalidad y aquí se sostiene por tamaño muestral. El percentil no supone forma, pero hereda el sesgo de la distribución *bootstrap*; el BCa lo corrige, pero falla en casos degenerados. En la validación completa, 37 de los 128 estimandos no admiten BCa: tasas constantes como el 100 % de atraso con descuento > 10, cuya réplica es siempre 1, o *jackknife* sin variación. En la tasa con descuento > 10 se conserva el IC de Wilson de S1, [0,9986; 1], porque el IC *bootstrap* [1; 1] no expresa certeza poblacional. Los

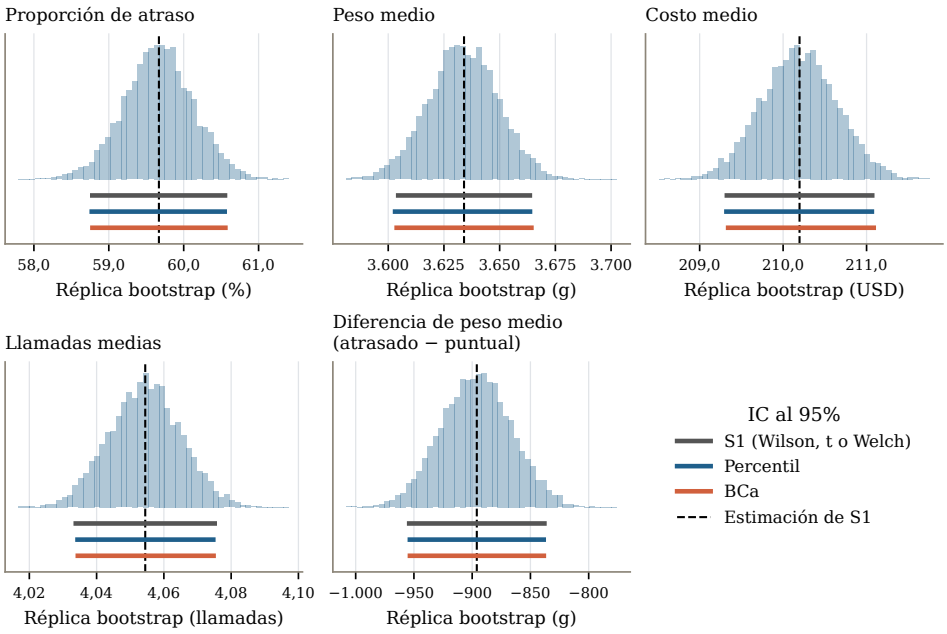


Figura 1: Distribuciones *bootstrap* de los cuatro parámetros de S1 y de la diferencia de peso, con el IC de S1, el percentil y el BCa.

extremos (mínimo y máximo) quedan solo como diagnóstico. Ningún método corrige una posible dependencia entre envíos.

2. Validación de pruebas de hipótesis mediante permutación

Se desarrolla **T02**, la asociación central de S1. H_0: el peso medio de los envíos atrasados es igual al de los puntuales; H_1 (bilateral): son distintos. El efecto es −896,0 g y t de Welch = −29,27. Si H_0 fuera cierta y los envíos intercambiables, cualquier reasignación de las etiquetas de atraso sería igual de probable. Por eso se permutan 10.000 veces, conservando los tamaños de los grupos, y se recalcula el t de Welch studentizado, robusto a varianzas distintas. Se usa $p_{perm} = (1 + \#\{|T^*| \geq |T_{obs}|\})/(B + 1)$, que nunca es cero (Phipson y Smyth, 2010). Como contraste se incluyen T03 (descuento por atraso), base de la auditoría, y T01 (modalidad, χ^2), la única prueba sin asociación en S1.

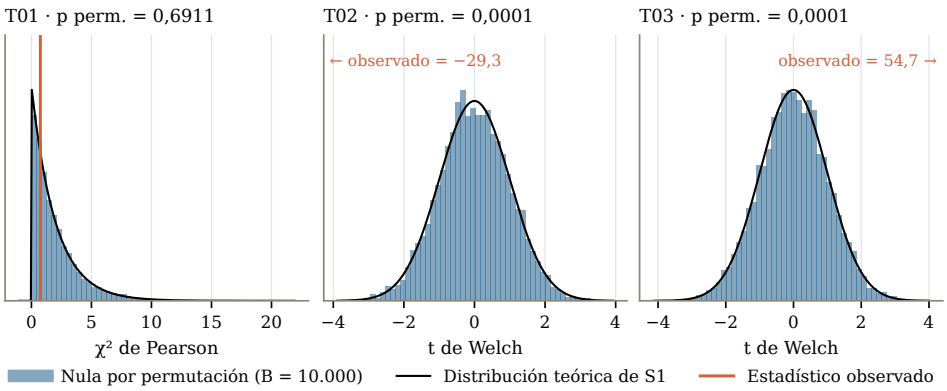


Figura 2: Distribuciones nulas por permutación ($B = 10.000$) frente a la distribución teórica usada en S1.

Tabla 2: Valor p de permutación frente al paramétrico de S1.

Prueba	Estadístico	Exced.	p_{perm} (MCSE)	p de S1	Decisión (5 %)
T02 peso	$t = -29{,}27$	0	$\leq 1/10.001$	$1{,}9 \cdot 10^{-180}$	Rechaza (ambos)
T03 descuento	$t = 54{,}70$	0	$\leq 1/10.001$	0 (subdesb.)	Rechaza (ambos)
T01 modalidad	$\chi^2 = 0{,}743$	6.911	0,691 (0,005)	0,690	No rechaza (ambos)

Concordancia. Ninguna de las 10.000 permutaciones alcanzó $|t| = 29{,}27$, y las decisiones coinciden con S1 (tabla 2). También coinciden con el ajuste de Holm sobre las siete pruebas: la cota de Bonferroni del p_{perm}, mayor o igual que el p de Holm, es 0,0007 en T02 y T03. En T01, los dos p difieren en 0,0016, menos de un MCSE. La figura 2 muestra además que **la distribución de referencia de S1 era adecuada**. La nula de T02 tiene media −0,008, DE 0,999 y valor crítico al 95 % de 1,94, frente al 1,96 de la t; la de T01 tiene crítico 6,10, frente a 5,99 de χ^2_2. Esto vale incluso en T03, cuyas DE del descuento son 19,1 y 2,9.

Qué enfoque es más apropiado. La permutación no supone normalidad, así que es la validación más robusta de la *decisión*. Su resolución, en cambio, está acotada por B: no distingue un p de 10^{-5} de uno de 10^{-180}. Conviene informar la decisión con la permutación y la magnitud con el p paramétrico, ya validado. El Anexo A extiende la comparación a las siete pruebas de S1, incluidas U de Mann–Whitney y z de proporciones: las siete coinciden con S1, en la familia cruda y con Holm.

3. Evaluación de estabilidad de correlaciones

S1 publicó correlaciones con su valor p, pero sin IC. Con $n = 10.999$, casi cualquier coeficiente resulta significativo, así que para S3 importan su magnitud y su estabilidad. Se eligen cinco: las dos asociaciones fuertes con el atraso (descuento y peso); la relación entre ambos predictores, que indica si se confunden; y dos asociaciones débiles (costo y compras previas), que permiten distinguir un efecto pequeño pero preciso de uno inestable. Se usa *bootstrap* de filas emparejadas ($B = 10.000$, IC percentil); en Spearman, los rangos se recalculan en cada réplica.

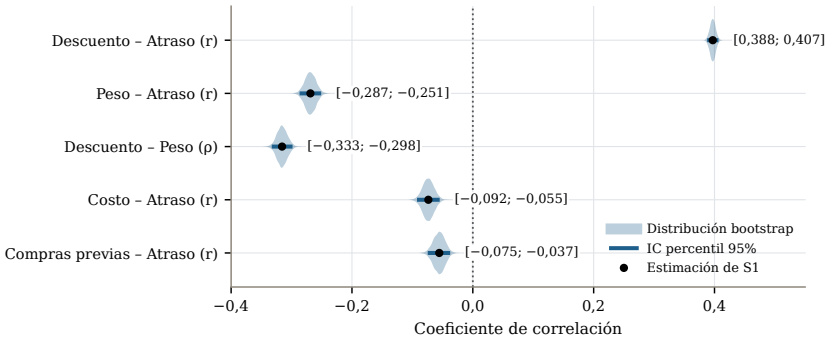


Figura 3: Distribución *bootstrap* e IC percentil al 95 % de cinco correlaciones de S1.

Tabla 3: Correlaciones de S1 con IC *bootstrap* al 95 %.

Relación	Coef. S1	IC 95 %	EE/$\lvert r \rvert$	Estabilidad (sección 5)
Descuento – atraso (r_{pb})	0,397	[0,388; 0,407]	1,2 %	Depende del desc. > 10
Peso – atraso (r_{pb})	−0,269	[−0,287; −0,251]	3,4 %	**Robusta**
Descuento – peso (ρ)	−0,316	[−0,333; −0,298]	2,8 %	Depende del desc. > 10
Costo – atraso (r_{pb})	−0,074	[−0,092; −0,055]	12,9 %	Débil, inestable
Compras previas – atraso (r_{pb})	−0,056	[−0,075; −0,037]	17,3 %	Débil, inestable

Con los datos completos, **ninguna correlación incluye el cero**. Los IC miden entre 0,019 y 0,037, y la distribución *bootstrap* es simétrica y sin sesgo apreciable ($\leq 0{,}0002$). Sin embargo, **precisión no es estabilidad**. Costo y compras previas explican menos del 0,6 % de la varianza del atraso (r^2) y tienen una variabilidad relativa de 13 % a 17 %; su signo está determinado, pero

su importancia práctica es mínima. La relación descuento–peso ($\rho = -0{,}316$) indica que los envíos con más descuento son más livianos, de modo que parte de la asociación de cada uno con el atraso puede deberse al otro. La estabilidad frente a la composición de la muestra se evalúa en la sección 5: solo peso–atraso conserva su IC lejos del cero en todos los escenarios. El Anexo B presenta las 20 correlaciones y las 15 V de Cramér.

4. Simulación Monte Carlo basada en parámetros de S1

Escenario. La revisión operacional que recomienda S1 examina *lotes* de envíos (una semana o una bodega) y compara su tasa de atraso con la de referencia. Para interpretar un lote hay que saber cuánto varía esa tasa *solo por azar* si el proceso es el de S1: ¿qué rango cabe esperar?, ¿con qué probabilidad se supera el 60 % sin cambios en el proceso?, ¿desde qué tasa un lote es inusual? El 60 % es ilustrativo (entero más cercano sobre la tasa de S1), no un objetivo de la empresa.

Modelo. Cada lote tiene $K \sim \text{Binomial}(N, p)$ atrasos, con $p = 6.563/10.999 = 0{,}5967$, **el parámetro estimado en S1**, y $N \in \{100, 500, 1.000, 5.000\}$, una decisión de escenario. Se simulan $B = 10.000$ lotes por tamaño (Robert y Casella, 2004). Las tolerancias se fijaron antes de ejecutar: $\text{MCSE}_{media} = s/\sqrt{B} \leq 0{,}001$ y $\text{MCSE}_{prob} = \sqrt{\hat{q}(1-\hat{q})/B} \leq 0{,}005$.

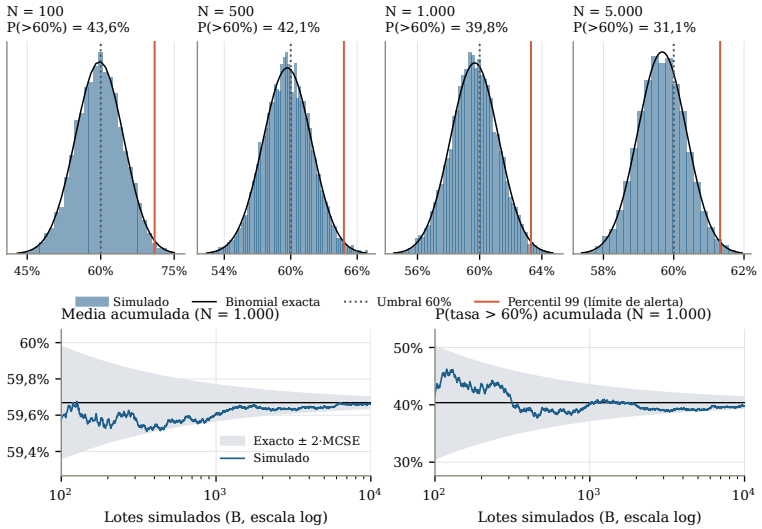


Figura 4: Arriba: tasa de atraso de 10.000 lotes simulados por tamaño, con la binomial exacta, el umbral de 60 % y el percentil 99. Abajo: convergencia de la media y de P(tasa > 60 %) en lotes de 1.000, con la banda exacta ±2 MCSE.

Tabla 4: Lotes simulados con p de S1 ($B = 10.000$ por tamaño).

N	Rango central 95 %	Percentil 99	P(tasa > 60 %)	Exacta	MCSE prob.
100	[50,0 %; 69,0 %]	71,0 %	43,6 %	43,5 %	0,005
500	[55,4 %; 64,0 %]	64,8 %	42,1 %	42,3 %	0,005
1.000	**[56,6 %; 62,7 %]**	**63,3 %**	**39,8 %**	**40,4 %**	0,005
5.000	[58,3 %; 61,1 %]	61,3 %	31,1 %	31,2 %	0,005

Interpretación. En un lote de 1.000 envíos, la tasa de atraso fluctúa entre 56,6 % y 62,7 % solo por azar, con una DE de 1,6 puntos porcentuales (4,9 con 100 envíos). Una auditoría que compare lotes pequeños verá diferencias de 10 puntos sin que exista un problema operacional. **Un umbral de 60 % no sirve como alerta**: como p está solo 0,33 puntos por debajo, un lote de 1.000 lo supera en el 40 % de los casos sin que nada cambie. Un límite coherente con S1 es el percentil 99 (63,3 % con 1.000 envíos): superarlo tiene una probabilidad menor que 1 % bajo el proceso de S1 y justifica revisar el lote.

Convergencia. Con $B = 10.000$ se cumplen ambas tolerancias ($\text{MCSE}_{media} \leq 0{,}0005$;

$\text{MCSE}_{prob} \leq 0{,}005$). La media y la DE coinciden con las binomiales, y las probabilidades quedan a menos de 2 MCSE de las exactas. La trayectoria acumulada permanece dentro de la banda exacta ±2 MCSE (figura 4). La coincidencia valida el simulador, no el modelo: los cuantiles están condicionados a p y a envíos independientes, y no son un IC de p. La sección 5 relaja ambos supuestos.

5. Análisis de robustez

***Jackknife*: ningún envío individual cambia una conclusión.** Al retirar cada uno de los 10.999 envíos, los parámetros cambian como máximo un 0,011 %, la diferencia de peso un 0,08 % y las correlaciones un 0,75 %. En T02 y T03, ningún envío cambia la decisión (el $|t|$ mínimo es 29,26 y 54,69). El EE *jackknife* coincide con el *bootstrap*, con razón entre 0,989 y 1,013, lo que confirma la incertidumbre por una tercera vía. Los envíos más influyentes, como el de mayor peso (`id_envio` 200), son valores válidos y no se eliminan. **El *jackknife* revela, en cambio, una estructura del archivo** (figura 5): los 3.135 primeros registros están *todos* atrasados y contienen *todos* los descuentos mayores que 10. Desde el `id_envio` 3.136, la tasa de atraso es 43,6 % y el peso medio, 4.140 g, frente a 2.366 g en el bloque inicial. El segmento que S1 propuso auditar coincide con un bloque contiguo del archivo, compatible con otro período, sistema o regla de registro.

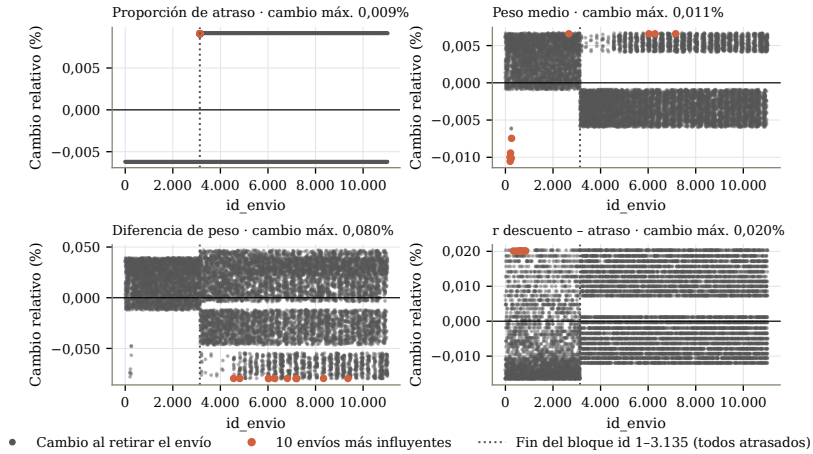


Figura 5: Cambio relativo de cuatro estimandos al retirar cada envío. La línea punteada marca el fin del bloque de `id_envio` 1–3.135.

Tabla 5: Resultados centrales de S1 en cada escenario (IC *bootstrap* 95 % entre corchetes).

Resultado	Completos	Winsor. 1/99	Excl. IQR ($n = 7.971$)	Desc. ≤ 10 ($n = 8.352$)
Diferencia de peso, T02 (g)	−896	−897	−450 ($p \leq 0{,}0001$)	−284 ($p \leq 0{,}0001$)
Diferencia de descuento, T03	13,12	13,12	0,86 ($p \leq 0{,}0001$)	−0,08 ($p = 0{,}186$)
r descuento – atraso	0,397	0,397	0,121	−0,014 [−0,036; 0,007]
r peso – atraso	−0,269	−0,270	−0,139	−0,088 [−0,109; −0,066]
ρ descuento – peso	−0,316	−0,316	−0,081	0,007 [−0,015; 0,028]
r costo – atraso	−0,074	−0,074	−0,010 [−0,033; 0,012]	0,003 [−0,018; 0,025]

Extremos y composición. La winsorización 1/99 de peso y costo modifica 425 envíos y no cambia ninguna conclusión: **los resultados no dependen de los valores extremos**. Los escenarios restringidos describen subpoblaciones, no correcciones, y muestran que **la composición sí importa** (tabla 5, figura 6). Al retirar el descuento > 10, la diferencia de descuento de T03 deja de ser significativa y r descuento–atraso pasa a incluir el cero: **la asociación del descuento con el atraso existe solo por ese segmento**. Lo mismo ocurre con la relación descuento–peso. El peso, en cambio, conserva signo, significancia e IC alejado del cero en todos los escenarios, aunque su magnitud cae a un tercio. Se observan dos discrepancias materiales en

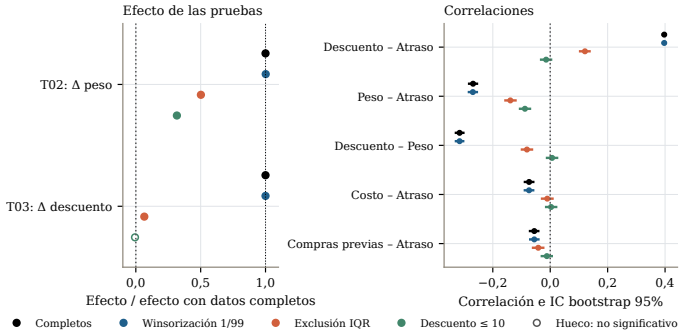


Figura 6: Efectos de T02 y T03 (relativos a los datos completos) y correlaciones con IC *bootstrap* por escenario. Hueco: no significativo.

las otras pruebas de S1. E4 (costo por atraso) deja de ser significativa con la exclusión IQR y con descuento ≤ 10 (Holm 0,71 y 1,00). E2 (atraso con importancia alta) pierde significancia con Holm en ambos escenarios (0,086 y 0,143). La modalidad (T01) no muestra asociación en ningún escenario.

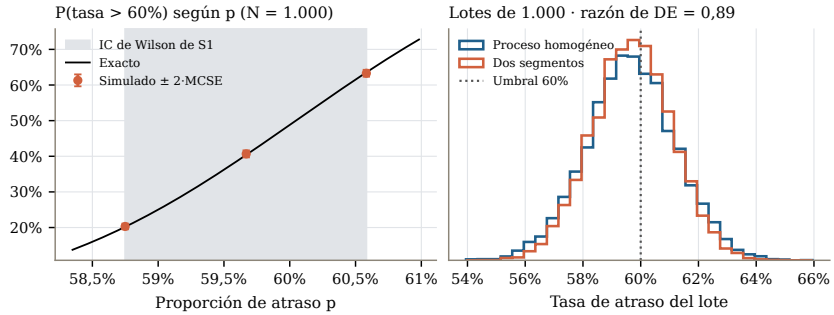


Figura 7: Izquierda: P(tasa $> 60\,\%$) en lotes de 1.000 según p dentro del IC de Wilson de S1. Derecha: proceso homogéneo frente a dos segmentos de descuento.

Supuestos del Monte Carlo. Con p en los extremos del IC de Wilson [58,75 %; 60,58 %] y uniformes comunes, P(tasa $> 60\,\%$) varía de 20,3 % a 63,3 %, mientras el percentil 99 se mueve menos de un punto (62,4 % a 64,2 %; figura 7). El percentil 99 es, por lo tanto, una alerta estable y el umbral fijo, no. Si cada lote conserva la composición de S1 (24 % con descuento > 10, todos atrasados; el resto con tasa 46,89 %), la DE baja un 11 % (razón 0,89) y el percentil 99 pasa de 63,3 % a 62,8 %. El modelo homogéneo es levemente conservador. Si la mezcla varía entre lotes, como sugiere el bloque de registros, la dispersión real sería mayor que la de ambos modelos.

6. Preparación para la Sumativa 3

Tabla 6: Resultados validados (síntesis de `outputs/resultados_validados.csv`; matriz completa en el Anexo C).

Resultado de S1	Estado	Evidencia de S2
Proporción de atraso, peso, costo y llamadas medios	Respaldados	IC *bootstrap*, BCa y *jackknife* coinciden con S1; sin influencia de extremos
Peso – atraso (T02, diferencia de peso, r_{pb})	Respaldado, magnitud sensible	Decisión y signo estables en todos los escenarios; efecto de −896 a −284 g
Descuento – atraso (T03, r_{pb}) y descuento – peso	Sensibles	Desaparecen sin el segmento > 10 (`id_envio` 1–3.134)
Costo y compras previas – atraso	Sensibles	Débiles; IC incluye 0 en escenarios restringidos
Modalidad – atraso (T01)	No concluyente	Sin asociación con ningún método ni escenario
Lotes de 1.000 envíos (Monte Carlo)	Sensible	Percentil 99 = 63,3 %; P(>60 %) depende de p (20 %–63 %)

Observaciones influyentes. Ningún envío individual debe eliminarse; lo influyente es el **bloque de registros 1–3.135**.

Recomendaciones metodológicas para S3.

1. **Verificar la procedencia del bloque 1–3.135** antes de modelar. Si proviene de otro origen, modelarlo aparte o con una variable indicadora.
2. **Modelar por segmento de descuento o con interacción.** En el segmento > 10 hay separación completa (100 % de atraso), que impide una regresión logística estándar; conviene penalizar o tratar ese segmento aparte.
3. **Conservar el peso** como predictor principal, con términos no lineales por su bimodalidad, y modelarlo junto con el descuento ($\rho = -0{,}32$).
4. **No basar decisiones en costo, compras previas ni modalidad.** No excluir envíos por la regla IQR ni winsorizar: no cambia las conclusiones y altera la población.
5. **Fijar alertas por tamaño de lote** con el percentil 99 simulado, revisado con el IC de p y por segmento.
6. **Mantener remuestreo y permutación como validación** y evaluar la dependencia por bodega o período (*bootstrap* por bloques) si se obtienen esas variables. La concordancia entre métodos no demuestra causalidad ni transportabilidad.

7. Bibliografía (APA 7)

Brown, L. D., Cai, T. T., & DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science, 16*(2), 101–133. https://doi.org/10.1214/ss/1009213286

Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association, 82*(397), 171–185. https://doi.org/10.1080/01621459.1987.10478410

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Gopalani, P. (2021). *E-Commerce Shipping Data* (versión 1) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/prachi13/customer-analytics

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Phipson, B., & Smyth, G. K. (2010). Permutation p-values should never be zero: Calculating exact p-values when permutations are randomly drawn. *Statistical Applications in Genetics and Molecular Biology, 9*(1), Artículo 39. https://doi.org/10.2202/1544-6115.1585

Robert, C. P., & Casella, G. (2004). *Monte Carlo statistical methods* (2.ª ed.). Springer.

Universidad de Chile. (s. f.). *Random UChile: Faro de aleatoriedad* [Servicio web]. https://random.uchile.cl

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*, 261–272. https://doi.org/10.1038/s41592-019-0686-2

Welch, B. L. (1947). The generalization of "Student's" problem when several different population variances are involved. *Biometrika, 34*(1–2), 28–35. https://doi.org/10.1093/biomet/34.1-2.28

Anexos

Pruebas, correlaciones y matriz de resultados validados de S1. No forman parte del cuerpo de siete páginas.

A Permutación de las siete pruebas de S1
B Las 20 correlaciones y las 15 asociaciones de S1
C Matriz de resultados validados para S3

Generados desde las tablas de `outputs/validacion_completa/` y `outputs/` con `docs/informe/generar_anexos.py`.

Anexo A. Permutación de las siete pruebas de S1

Cada prueba conserva la hipótesis, los grupos y el estadístico de S1, recalculado en cada una de las $B = 10.000$ permutaciones (flujo `permutaciones`). Se usa $p_{perm} = (1 + \text{excedencias})/(B + 1)$, con resolución 1/10.001; cola superior para χ^2, bilateral para t y z, y distancia al centro $n_1 n_0/2$ para U. Holm se aplica a la familia de los siete p de permutación y se compara con la familia Holm de S1. Fuente: `permutaciones_todas.csv`.

Tabla A-1: Siete pruebas de S1: valor p de permutación frente al paramétrico, crudo y con Holm.

ID	Variable	Estad.	Observado	Efecto	Exced.	p_{perm}	Holm perm.	p S1	Holm S1	Conc.
T01	Modalidad	χ^2	0,7434	0,0082	6.911	0,6911	0,6911	0,6895	0,6895	Sí
T02	Peso	t Welch	−29,27	−896,03	0	$1{,}00 \cdot 10^{-4}$	$7{,}00 \cdot 10^{-4}$	$1{,}93 \cdot 10^{-180}$	$9{,}65 \cdot 10^{-180}$	Sí
T03	Descuento	t Welch	54,70	13,12	0	$1{,}00 \cdot 10^{-4}$	$7{,}00 \cdot 10^{-4}$	0[s]	0[s]	Sí
E1	Peso (rangos)	U	10.000.332,5	−0,3130	0	$1{,}00 \cdot 10^{-4}$	$7{,}00 \cdot 10^{-4}$	$3{,}40 \cdot 10^{-171}$	$1{,}36 \cdot 10^{-170}$	Sí
E2	Importancia alta	z	3,4863	0,0581	7	$8{,}00 \cdot 10^{-4}$	0,0016	$4{,}90 \cdot 10^{-4}$	$9{,}80 \cdot 10^{-4}$	Sí
E3	Descuento > 10	z	48,54	0,5311	0	$1{,}00 \cdot 10^{-4}$	$7{,}00 \cdot 10^{-4}$	0[s]	0[s]	Sí
E4	Costo	t Welch	−7,7471	−7,2095	0	$1{,}00 \cdot 10^{-4}$	$7{,}00 \cdot 10^{-4}$	$1{,}04 \cdot 10^{-14}$	$3{,}11 \cdot 10^{-14}$	Sí

Efecto: diferencia atrasada − puntual (T02, T03, E4), V de Cramér (T01), biserial de rangos (E1) y diferencia de proporciones (E2, E3). Conc.: la decisión al 5 % coincide con S1 en la familia cruda y en la ajustada por Holm. E2: importancia alta frente al resto; E3: descuento > 10 frente a ≤ 10. [s] Subdesbordamiento numérico en S1, no una probabilidad nula.

Las distribuciones nulas de T01, T02 y T03 se muestran en la figura 2 del cuerpo; las de E1 a E4, en las figuras A-1–A-4.

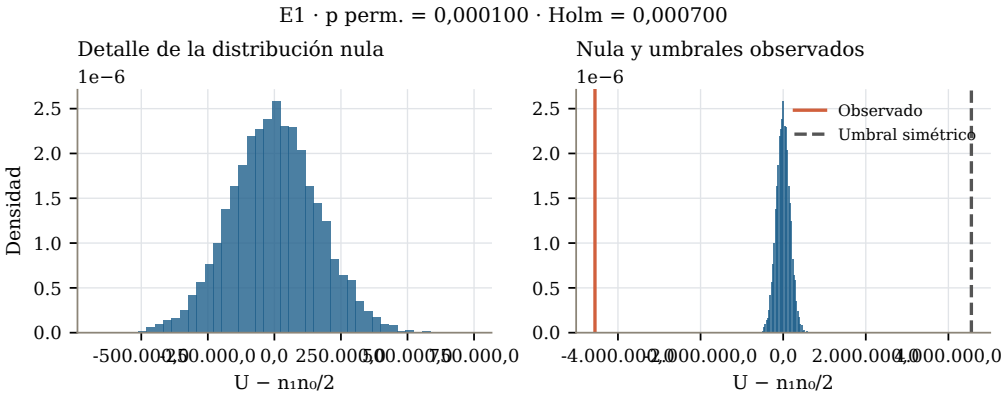


Figura A-1: Distribución nula por permutación: E1, U de Mann–Whitney del peso.

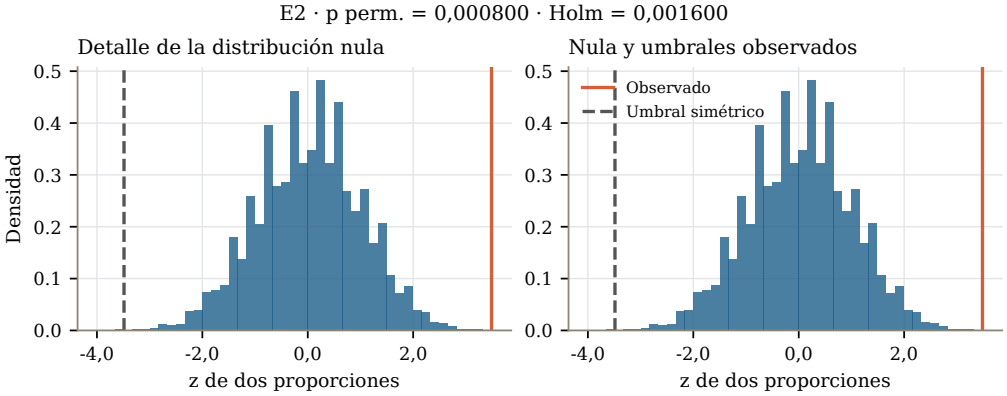


Figura A-2: Distribución nula por permutación: E2, z de dos proporciones (importancia alta / resto).

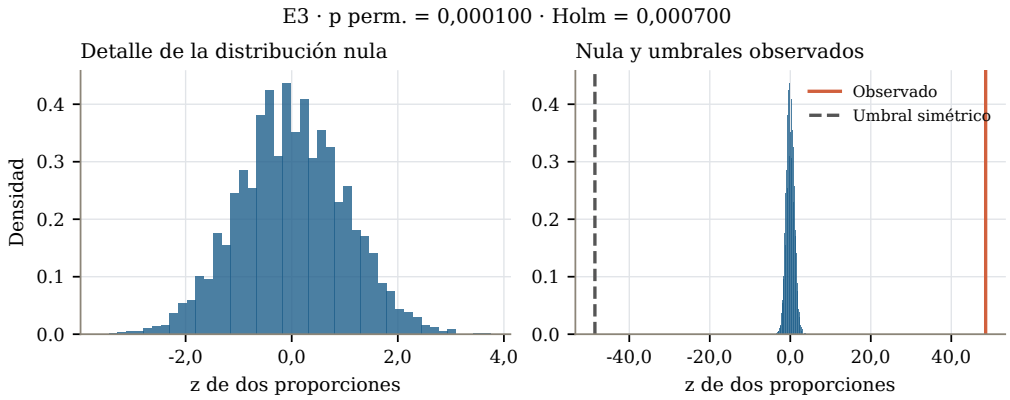


Figura A-3: Distribución nula por permutación: E3, z de dos proporciones (descuento > 10 / ≤ 10).

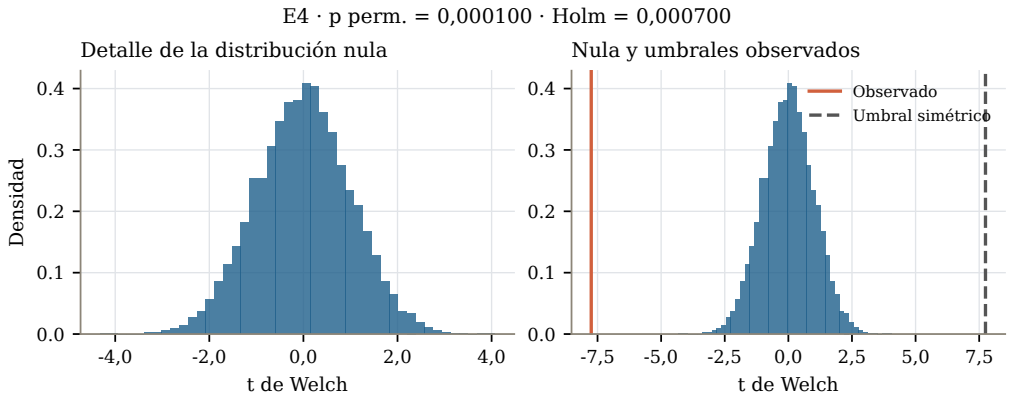


Figura A-4: Distribución nula por permutación: E4, t de Welch del costo.

Anexo B. Las 20 correlaciones y las 15 asociaciones de S1

Bootstrap de filas emparejadas con $B = 10.000$ (flujo `bootstrap_coeficientes`) e IC percentil al 95 %; en Spearman, los rangos se recalculan en cada réplica. Las mismas remuestras sirven para los 35 coeficientes. Para la V de Cramér, acotada en $[0, 1]$, el IC describe magnitud y precisión: un IC positivo no prueba dependencia, porque el estimador está sesgado hacia arriba cerca de cero. Fuentes: `correlaciones_bootstrap.csv` y `asociaciones_bootstrap.csv`.

Tabla B-1: Las 20 correlaciones de S1 con IC *bootstrap* percentil.

ID	Coef.	Par	S1	Sesgo	EE	IC 95 %	Ancho	Incluye 0
COR-011	r_{pb}	Compras previas – Atraso	−0,0555	$-2{,}13 \cdot 10^{-4}$	0,0096	[−0,075; −0,037]	0,037	No
COR-012	r_{pb}	Costo – Atraso	−0,0736	$-3{,}68 \cdot 10^{-5}$	0,0095	[−0,092; −0,055]	0,038	No
COR-013	r_{pb}	Descuento – Atraso	0,3971	$1{,}78 \cdot 10^{-5}$	0,0047	[0,388; 0,407]	0,019	No
COR-014	r_{pb}	Llamadas – Atraso	−0,0671	$-7{,}24 \cdot 10^{-5}$	0,0096	[−0,086; −0,048]	0,038	No
COR-015	r_{pb}	Peso – Atraso	−0,2688	$-4{,}55 \cdot 10^{-5}$	0,0092	[−0,287; −0,251]	0,036	No
COR-016	ρ	Compras previas – Costo	0,1942	$6{,}22 \cdot 10^{-5}$	0,0091	[0,176; 0,212]	0,036	No
COR-017	ρ	Compras previas – Descuento	−0,0939	$-5{,}59 \cdot 10^{-5}$	0,0095	[−0,112; −0,075]	0,037	No
COR-018	ρ	Compras previas – Atraso	−0,0746	$-1{,}74 \cdot 10^{-4}$	0,0096	[−0,094; −0,056]	0,037	No
COR-019	ρ	Compras previas – Llamadas	0,2730	$-5{,}26 \cdot 10^{-5}$	0,0086	[0,256; 0,290]	0,034	No
COR-020	ρ	Compras previas – Peso	−0,2347	$9{,}01 \cdot 10^{-5}$	0,0092	[−0,253; −0,216]	0,036	No
COR-021	ρ	Costo – Descuento	−0,1158	$-5{,}81 \cdot 10^{-5}$	0,0093	[−0,134; −0,098]	0,037	No
COR-022	ρ	Costo – Atraso	−0,0719	$-3{,}25 \cdot 10^{-5}$	0,0095	[−0,090; −0,053]	0,037	No
COR-023	ρ	Costo – Llamadas	0,2937	$7{,}35 \cdot 10^{-5}$	0,0095	[0,275; 0,312]	0,037	No
COR-024	ρ	Costo – Peso	−0,1320	$3{,}58 \cdot 10^{-5}$	0,0102	[−0,152; −0,112]	0,040	No
COR-025	ρ	Descuento – Atraso	0,3351	$-8{,}14 \cdot 10^{-5}$	0,0083	[0,319; 0,351]	0,033	No
COR-026	ρ	Descuento – Llamadas	−0,1042	$8{,}66 \cdot 10^{-5}$	0,0095	[−0,123; −0,085]	0,037	No
COR-027	ρ	Descuento – Peso	−0,3157	$9{,}76 \cdot 10^{-5}$	0,0087	[−0,333; −0,298]	0,034	No
COR-028	ρ	Llamadas – Atraso	−0,0643	$-6{,}97 \cdot 10^{-5}$	0,0096	[−0,083; −0,046]	0,037	No
COR-029	ρ	Llamadas – Peso	−0,2329	$2{,}96 \cdot 10^{-5}$	0,0095	[−0,252; −0,214]	0,037	No
COR-030	ρ	Peso – Atraso	−0,2660	$-1{,}80 \cdot 10^{-5}$	0,0093	[−0,284; −0,248]	0,036	No

Tabla B-2: Las 15 asociaciones V de Cramér de S1 con IC *bootstrap* percentil.

ID	Par	V S1	Media boot.	Sesgo	EE	IC 95 %	Ancho
ASO-001	Bodega – Calificación	0,0151	0,0240	0,0089	0,0039	[0,017; 0,032]	0,015
ASO-002	Bodega – Atraso	0,0100	0,0202	0,0103	0,0072	[0,008; 0,036]	0,028
ASO-003	Bodega – Género	0,0087	0,0197	0,0111	0,0070	[0,008; 0,034]	0,027
ASO-004	Bodega – Importancia	0,0191	0,0265	0,0074	0,0058	[0,016; 0,038]	0,023
ASO-005	Bodega – Modalidad	0,0011	0,0186	0,0175	0,0047	[0,010; 0,028]	0,018
ASO-006	Calificación – Atraso	0,0171	0,0243	0,0072	0,0080	[0,009; 0,041]	0,031
ASO-007	Calificación – Género	0,0164	0,0239	0,0075	0,0080	[0,009; 0,041]	0,031
ASO-008	Calificación – Importancia	0,0181	0,0256	0,0075	0,0057	[0,015; 0,037]	0,022
ASO-009	Calificación – Modalidad	0,0170	0,0250	0,0079	0,0056	[0,015; 0,036]	0,022
ASO-010	Género – Atraso	0,0047	0,0086	0,0039	0,0064	[0,000; 0,024]	0,023
ASO-011	Género – Importancia	0,0100	0,0151	0,0051	0,0075	[0,003; 0,031]	0,029
ASO-012	Género – Modalidad	0,0182	0,0210	0,0028	0,0087	[0,005; 0,039]	0,034
ASO-013	Importancia – Atraso	0,0333	0,0348	0,0015	0,0092	[0,017; 0,053]	0,036
ASO-014	Importancia – Modalidad	0,0100	0,0158	0,0058	0,0055	[0,006; 0,028]	0,022
ASO-015	Modalidad – Atraso	0,0082	0,0140	0,0058	0,0071	[0,003; 0,029]	0,027

El sesgo positivo en las V cercanas a cero es esperable: la V remuestreada nunca es negativa. Las asociaciones con el atraso (T01 incluida) se validan una vez y se referencian desde el Anexo A.

Anexo C. Matriz de resultados validados para S3

La tabla C-1 reproduce `outputs/resultados_validados.csv`, archivo de entrada a S3, con el estado y la recomendación de cada resultado discutido en el cuerpo. La tabla C-2 comprueba la cobertura del 100 % del inventario: cada uno de los 194 resultados de S1 tiene una validación o una excepción metodológica explícita.

Tabla C-1: Resultados validados, estado y recomendación para S3.

ID	Resultado	Estado	Recomendación para S3
PAR-1	Proporción de atraso	respaldado	Usar 59,67 % [58,75; 60,58] como tasa de referencia; reportar por segmento de descuento.
PAR-2	Peso medio	respaldado	Media válida como resumen, pero el peso es bimodal: modelar con tramos o términos no lineales.
PAR-3	Costo medio	respaldado	Variable de bajo poder explicativo para el atraso; conservar solo como control.
PAR-4	Llamadas medias	respaldado	Media estable; las llamadas pueden ser posteriores al envío: revisar su temporalidad antes de usarlas como predictor.
EFE-1	Diferencia de peso medio (atrasado − puntual)	respaldado, magnitud sensible	Incluir el peso en S3; su efecto se reduce fuera del descuento alto: estimar interacción peso × segmento.
T01	Prueba χ^2 de independencia entre modalidad de envío y atraso	no concluyente	No priorizar la modalidad de envío; no rechazar no demuestra igualdad.
T02	Prueba t de Welch de peso medio entre envíos atrasados y puntuales	respaldado, magnitud sensible	Asociación peso–atraso robusta en dirección; reportar el tamaño por segmento.
T03	Prueba t de Welch de descuento medio entre envíos atrasados y puntuales	sensible	La diferencia de descuento depende del segmento > 10 (ids 1 a 3.134): auditar su procedencia antes de modelar.
COR-1	r punto-biserial Descuento – Atraso	sensible	La asociación existe solo por el segmento > 10, todo atrasado y contenido en los 3.135 primeros registros; modelarlo aparte (separación completa).
COR-2	r punto-biserial Peso – Atraso	respaldado, magnitud sensible	Conservar el peso: la única correlación que excluye el cero en todos los escenarios.
COR-3	ρ de Spearman Descuento – Peso	sensible	Descuento y peso están relacionados: modelarlos conjuntamente para evitar confusión.
COR-4	r punto-biserial Costo – Atraso	sensible	Correlación débil y sensible: no fundamentar decisiones en ella.
COR-5	r punto-biserial Compras previas – Atraso	sensible	Correlación débil y sensible: no fundamentar decisiones en ella.
MC-1	Tasa de atraso en lotes de 1.000 envíos	sensible	Fijar límites de alerta por tamaño de lote y en relación con el IC de p; segmentar por descuento.

Tabla C-2: Cobertura del inventario de S1 por familia.

Familia	Resultados	Técnica principal	*Jk* evaluado	*Jk* no aplica	Anexos
Parametros	4	Bootstrap percentil y BCa	4	0	—
Efectos	13	Bootstrap por grupo, percentil y BCa	13	0	—
Descriptivas	111	Bootstrap percentil y BCa; extremos solo diagnóstico	111	0	—
Pruebas	21	Permutación y Holm	7	14	A
Correlaciones	30	Bootstrap emparejado percentil	20	10	B
Asociaciones	15	Bootstrap emparejado percentil	15	0	B
Total	194		170	24	

Inventario: `inventario_resultados_s1.csv` (194 resultados únicos tras deduplicar las tablas de S1). —: detalle no incluido en los anexos. Todos los resultados entran además en el Monte Carlo empírico y en los escenarios del notebook de validación completa.