

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Cierre y Comunicación del Proyecto

Informe final integrado · 60 %

Título del proyecto:	Factores asociados al atraso en envíos de comercio electrónico: del análisis exploratorio a la clasificación
Integrantes:	José Ignacio Rodríguez, Yerko Gallardo Miranda y Sebastián Rojas Araya
Dataset:	*E-Commerce Shipping Data* (Gopalani, 2021), 10.999 envíos
Docente:	J. P. Maidana
Fecha:	28/10/2026
Repositorio GitHub:	`https://github.com/joserodriguezc/grupo_1_estadistica_computacional`

Resumen ejecutivo

(Pendiente.)

1. Introducción

Una empresa de comercio electrónico de productos electrónicos registró 10.999 envíos (Gopalani, 2021), de los cuales el **59,67 %** llegó atrasado (IC de Wilson al 95 %: [58,75; 60,58]). El proyecto se organizó en tres fases que se apoyan una en otra.

Sumativa 1 (S1): análisis exploratorio e inferencial. Preguntó *qué características se asocian con el atraso y qué evidencia orienta una revisión operacional*. Encontró que los envíos atrasados pesan en promedio 896 g menos que los puntuales ($d_{av} = -0{,}57$) y reciben 13,1 unidades más de descuento ($d_{av} = 0{,}96$), mientras que la modalidad de envío no se asocia con el atraso (p de Holm = 0,69). Recomendó auditar los 2.647 envíos con descuento mayor que 10, todos atrasados.

Sumativa 2 (S2): validación por remuestreo y simulación. Confirmó los intervalos y las decisiones de S1 con *bootstrap* y permutación ($B = 10.000$). Sus escenarios de sensibilidad mostraron que **el peso es la única asociación robusta**: la del descuento existe solo por el segmento con descuento mayor que 10, y el *jackknife* reveló que ese segmento coincide con los envíos 1 a 3.135 del archivo. La Formativa 2 ensayó una regresión logística con esos hallazgos: alcanzó un área bajo la curva ROC (AUC) de 0,714, pero de solo 0,52 en los envíos con descuento ≤ 10.

Sumativa 3 (S3): modelamiento. Esta fase pasa de describir asociaciones a **clasificar el atraso**. Cada decisión se fundamenta en un resultado de S1 o de S2:

- manejo de datos faltantes, con imputación por regresión lineal múltiple y comparación de estrategias;
- tres modelos de regresión logística en el segmento con descuento ≤ 10 (variables de S1 y S2, *stepwise* por AIC y reducido por BIC), con una regla para el segmento > 10, todo atrasado;
- estabilidad de los coeficientes por *bootstrap* y diagnóstico de supuestos;
- impacto de la estrategia de imputación sobre el modelo final.

La sección 2 describe la metodología integrada, la 3 presenta los resultados, la 4 los discute y la 5 formula las recomendaciones.

2. Metodología integrada

2.1 Datos, trazabilidad y punto de partida

Datos y reproducibilidad. Antes de usar el CSV original de S1, el notebook maestro verifica su huella SHA-256; el archivo se lee desde `sumativa_1/data/raw/`, sin copiarlo. Las cifras de S1, S2 y la Formativa 2 se leen desde sus tablas publicadas, sin recalcularse. Toda la aleatoriedad usa la semilla de S2 (`1505514103`), obtenida del pulso 1.053.589 del faro de aleatoriedad de la Universidad de Chile. De `SeedSequence(SEMILLA).spawn(10)` se derivan flujos independientes: los siete primeros son los de S2, el octavo es el de la Formativa 2, el noveno simula los faltantes y el décimo alimenta el *bootstrap* de S3.

Partición común. La partición 70/30, estratificada por el atraso, se define una sola vez sobre los 10.999 envíos: 7.699 de entrenamiento y 3.300 de prueba, ambos con 59,67 % de atraso. Es la misma de la Formativa 2. Todas las estrategias de imputación y todos los modelos usan esos mismos envíos, de modo que las diferencias entre resultados no dependen del azar de la partición. La preparación, el ajuste y las métricas usan funciones compartidas; con los datos completos, reproducen el AUC de la Formativa 2 (0,721).

Punto de partida. S1 registró **cero valores faltantes** en las 12 variables, por lo que el análisis de faltantes parte de un 0 % sin patrón. Las relaciones entre las variables numéricas son

débiles: ningún $|\rho|$ de Spearman supera 0,32 (figura 1). S2 distinguió dos grupos. El bloque peso–costo–compras previas–llamadas es **estable**: sus seis correlaciones excluyen el cero en los cuatro escenarios de sensibilidad. Las cuatro correlaciones del descuento son **inestables**: se anulan al retirar el segmento con descuento mayor que 10. La tabla 1 resume cómo estos hallazgos orientan cada decisión de S3.

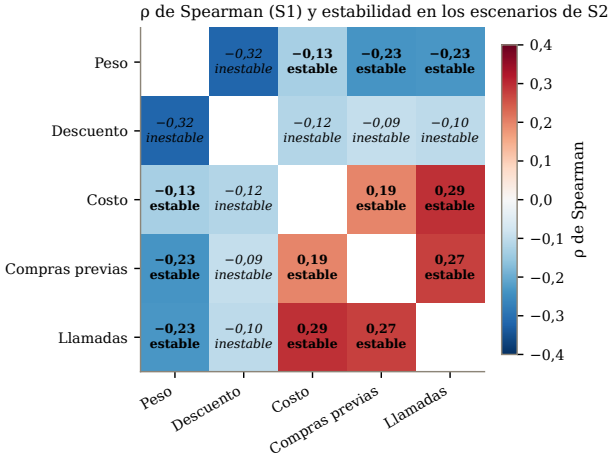


Figura 1: Correlaciones de Spearman entre las variables numéricas (S1) y su estabilidad en los cuatro escenarios de sensibilidad de S2. En negrita, las que excluyen el cero en todos los escenarios.

Tabla 1: Hallazgos de S1 y S2 que fundamentan las decisiones de S3.

Hallazgo previo	Fuente	Decisión en S3
Ningún valor faltante en 10.999 envíos	S1	Simular faltantes con un mecanismo conocido para ejercitar la imputación
Matriz de Spearman entre variables numéricas	S1	Origen de los predictores de cada regresión de imputación
Bloque peso–costo–compras–llamadas estable; descuento inestable	S2	Priorizar predictores estables al imputar
Extremos IQR válidos; winsorizar no cambia nada y excluir cambia la población	S1, S2	Conservar los outliers
Peso robusto; descuento dependiente del segmento > 10 (100 % atrasado); costo y compras débiles	S1, S2, F2	Modelos en el segmento ≤ 10 y regla para > 10; variables del modelo basado en S1 y S2
Modalidad sin asociación (T01)	S1, S2	Candidata solo para la selección automática
Llamadas y calificación posiblemente posteriores a la entrega	S1	Excluidas como predictores del atraso
Envíos 1 a 3.135 todos atrasados	S2	Excluir el identificador (fuga de información)
IC percentil y BCa validados con $B = 10.000$	S2	Mismo método para la estabilidad del modelo final

2.2 Datos faltantes e imputación por regresión

Simulación de faltantes (S1 → S3). Como S1 no registró faltantes, se eliminó cerca del 10 % de los valores de las cuatro variables numéricas candidatas a predictor (peso, costo, compras previas y descuento) mediante un mecanismo **de faltantes al azar condicionados a lo observado (MAR)**, declarado de antemano. La probabilidad de faltar es una función logística de variables completas (importancia, bodega, modalidad y género), con efectos distintos para cada variable y un intercepto calibrado para una tasa media del 10 %. Por diseño, el mecanismo no depende del valor propio, lo que lo haría no aleatorio (MNAR), ni del atraso, para no contaminar la evaluación posterior. El mecanismo se verificó con una regresión logística del indicador de faltante: la prueba de razón de verosimilitud (LR) sobre las variables observadas contrasta la hipótesis de faltantes completamente al azar (MCAR), y el coeficiente del valor propio contrasta la de MNAR.

Imputación por regresión lineal múltiple (S1 y S2 → S3). Se ajustó una regresión por

variable, por mínimos cuadrados con sus casos completos. Los predictores se tomaron de la matriz de Spearman de S1 con una regla explícita: se incluyen las correlaciones estables en los cuatro escenarios de S2, se agregan las inestables con $|\rho| \geq 0{,}30$ y, si quedan menos de tres, se usan todas las candidatas. Así, el peso se imputa con descuento, compras previas, llamadas y costo; el costo y las compras previas, con sus tres correlatos estables; y el descuento, sin ninguna correlación estable en S2, con las cuatro candidatas. El atraso nunca es predictor. Se evaluaron los supuestos de linealidad, homocedasticidad (Breusch-Pagan), normalidad (Jarque-Bera), independencia (Durbin-Watson) y multicolinealidad (VIF), y el desempeño mediante R^2 y la raíz del error cuadrático medio (RMSE) con validación cruzada de 5 particiones. Cuando un predictor también faltaba, se completó provisionalmente con su mediana; las predicciones se recortaron al rango observado y se redondearon, porque las cuatro variables son enteras.

Comparación de estrategias. La imputación por regresión se comparó con la eliminación de filas incompletas y con la imputación por la mediana, con cinco criterios: (a) tamaño resultante; (b) distribución frente a los datos originales (media, DE y prueba de Kolmogorov-Smirnov, KS); (c) preservación de las correlaciones de Spearman de S1; (d) error frente al **valor real**, que se conoce porque los faltantes son simulados; y (e) asignación al segmento de descuento de S1 (> 10, todo atrasado), que la Parte 2 usa para separar el modelo de la regla.

2.3 Regresión logística: preparación, selección y evaluación

Preparación informada por S1 y S2. Se utiliza el dataset elegido de imputación por regresión y la partición común de la sección 2.1. Se conservan los extremos: S1 los identificó como válidos y S2 mostró que winsorizar no alteraba las conclusiones. Las numéricas se estandarizan con media y desviación estándar (DE) del entrenamiento; las categóricas se codifican mediante indicadores, omitiendo el primer nivel ordenado como referencia. Se excluyen el identificador por la estructura detectada en S2, y llamadas y calificación por su posible registro posterior a la entrega.

Tres especificaciones. M1 incorpora peso, descuento, costo y compras previas, por las asociaciones de S1 y la continuidad con la Formativa 2; solo el peso fue robusto en todos los escenarios de S2. M2 considera además importancia, bodega, modalidad y género mediante selección *stepwise* bidireccional desde el intercepto, con entrada $p < 0{,}05$ y salida $p > 0{,}10$. Se emplean pruebas de razón de verosimilitudes, con las categorías de cada variable tratadas como un bloque. M3 minimiza el criterio de información bayesiano (BIC) entre los 256 subconjuntos de las ocho variables, incluido el intercepto solo; se informa también el criterio de información de Akaike (AIC). Ambos procedimientos utilizan exclusivamente entrenamiento. Los ajustes se realizan por máxima verosimilitud; se reportan coeficientes y razones de odds (OR) con intervalos de confianza (IC) de Wald al 95 %.

Evaluación y elección. Con umbral fijo 0,5 se calculan matrices de confusión, exactitud, precisión, sensibilidad, F1 y especificidad, además de curvas ROC y AUC, en entrenamiento y prueba. La referencia es la clase mayoritaria del entrenamiento. Se consideran elegibles los modelos a no más de 0,005 de la mayor AUC de prueba y se elige el menor BIC; los empates se resuelven por número de parámetros y nombre. La tolerancia es práctica, no una prueba de equivalencia. Se examinan costos relativos de falsos negativos (FN) frente a falsos positivos (FP) de 1, 2 y 5, sin atribuirles valores monetarios reales.

Alcance. La evaluación es exploratoria: prueba participa en la elección y la imputación principal se ajustó antes de separar los conjuntos. Aunque no utiliza el atraso, incorpora información de los predictores de prueba. Además, llamadas interviene indirectamente en la imputación, por lo que su disponibilidad temporal debe revisarse antes de uso operacional. Los IC son condicionales al modelo y al dataset imputado; no incorporan incertidumbre por selección o imputación.

2.4 Estabilidad y diagnóstico

Estabilidad por *bootstrap* (S2 → S3). Con el mismo método que S2 validó, se aplicó un *bootstrap* no paramétrico por pares a los coeficientes: $B = 10.000$ remuestras con reemplazo de los 5.572 envíos de entrenamiento del segmento ≤ 10, con el flujo de semilla reservado para S3. En cada remuestra se reajustaron los tres modelos con las mismas filas. Para cada coeficiente se calcularon los IC 95 % percentil y BCa (aceleración por *jackknife*), comparados con el IC de Wald; la razón entre el error estándar (EE) *bootstrap* y el de Wald, y el **porcentaje de réplicas que conservan el signo** de la estimación. Un coeficiente se considera **inestable** si su IC BCa incluye el cero (el de su OR incluye el 1), si conserva el signo en menos del 97,5 % de las réplicas o si su EE *bootstrap* supera en más de un 20 % al de Wald.

(Pendiente: diagnóstico.)

3. Resultados integrados

3.1 Datos faltantes e imputación

Faltantes simulados. Cada variable perdió entre el 9,6 % y el 10,1 % de sus valores (tabla 2); 3.786 envíos (34,4 %) tienen al menos un faltante y quedan 7.213 casos completos. El mecanismo es MAR: la prueba LR rechaza MCAR en las cuatro variables (χ^2_9 entre 128,4 y 174,2; $p < 0{,}001$), mientras que el valor propio no aporta una vez controladas las observadas (p entre 0,17 y 0,65).

Tabla 2: Faltantes simulados y desempeño de las regresiones de imputación (R^2 y RMSE con validación cruzada de 5 particiones).

Variable	Faltantes	%	Predictores	n de ajuste	R^2	RMSE / DE
Peso	1.086	9,87	Descuento, compras, llamadas, costo	7.213	0,272	0,85
Costo	1.107	10,06	Llamadas, compras, peso	8.043	0,111	0,94
Compras previas	1.055	9,59	Llamadas, peso, costo	8.043	0,054	0,97
Descuento	1.112	10,11	Peso, costo, llamadas, compras	7.213	0,217	0,88

Regresiones de imputación. Como anticipaban las correlaciones débiles de S1 ($|\rho| \leq 0{,}32$), la capacidad predictiva es modesta: el RMSE equivale al 85–97 % de la DE de cada variable. El R^2 de validación cruzada coincide con el de ajuste, por lo que no hay sobreajuste, y todos los coeficientes tienen el signo de la ρ de S1. Jarque-Bera y Breusch-Pagan rechazan normalidad y homocedasticidad, esperable en variables discretas y acotadas, pero ambas violaciones afectan a los errores estándar y no a la predicción puntual que usa la imputación. Durbin-Watson indica autocorrelación en peso (1,01) y descuento (1,33), coherente con el orden del archivo que detectó S2; el VIF máximo es 1,21. Se imputaron 4.360 valores; entre 189 y 282 por variable usaron un predictor provisional y 29 predicciones se recortaron al rango observado.

Tabla 3: Comparación de las tres estrategias. En negrita, el mejor valor de cada criterio.

Criterio	Eliminación	Mediana	Regresión
(a) Envíos conservados	7.213	**10.999**	**10.999**
(a) Entrenamiento / prueba	5.058 / 2.155	**7.699 / 3.300**	**7.699 / 3.300**
(b) KS medio frente al original	**0,004**	0,048	0,030
(b) DE relativa media	**1,00**	0,95	0,96
(c) Máx. $\lvert\Delta\rho\rvert$ entre numéricas (S1)	**0,012**	0,027	0,043
(c) Máx. $\lvert\Delta\rho\rvert$ con el atraso (S1)	**0,006**	0,023	0,012
(d) RMSE / DE frente al valor real	—	1,05	**0,92**
(e) Envíos en el segmento equivocado	**0**	268	447
(e) Atraso en el segmento > 10 (S1: 100 %)	**100 %**	**100 %**	92,6 %

Comparación y decisión. La tabla 3 y la figura 2 muestran un compromiso:

- La **eliminación** conserva distribuciones, correlaciones y segmentos, porque las variables que generan los faltantes se relacionan poco con las numéricas. A cambio, pierde el 34,4 % de los envíos y reduce el entrenamiento a 5.058.

- La **mediana** es la peor en casi todos los criterios. Atenúa la correlación del descuento con el atraso (0,313 frente a 0,335 en S1) y, al imputar el descuento con 7, lleva al segmento ≤ 10 a 268 envíos con descuento real > 10, todos atrasados.
- La **regresión** conserva la muestra completa y tiene el menor error frente al valor real. Mantiene la relación con el atraso de los dos predictores principales de S1: descuento (0,333) y peso ($-0{,}265$ frente a $-0{,}266$). Su costo es el de toda imputación determinista: reduce la variabilidad, acentúa la correlación peso–descuento ($-0{,}316 \rightarrow -0{,}359$) y, al predecir descuentos cerca de la media, desplaza al segmento > 10 a 428 envíos con descuento real ≤ 10.

Se eligió la **imputación por regresión**, con esa limitación explícita, y la eliminación quedó como referencia de sensibilidad; su efecto en el modelo final se cuantifica en el análisis de impacto de la imputación.

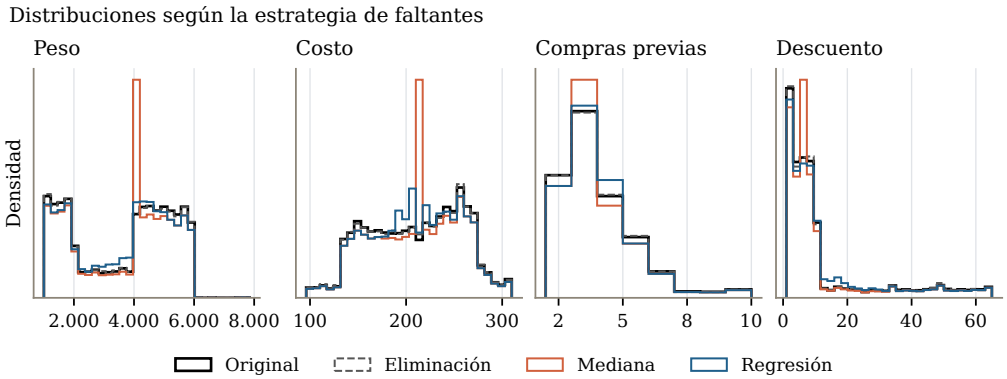


Figura 2: Distribución de cada variable según la estrategia de faltantes, frente a los datos originales.

Trazabilidad: `faltantes_resumen_variables.csv`, `faltantes_verificacion_mar.csv`, `imputacion_modelos.csv`, `imputacion_conteo.csv` y `estrategias_resumen.csv`.

3.2 Modelos logísticos y desempeño

Especificaciones y selección. M1 y M3 coinciden en las cuatro variables numéricas. M2 añade importancia del producto, pero no modalidad, bodega ni género. La exclusión de modalidad es coherente con S1/S2. La tabla 4 muestra que la mejora de AUC de M2 es pequeña (0,0008), mientras BIC favorece M1/M3. Se elige **M1**, por desempate entre especificaciones idénticas. Esto favorece parsimonia dentro de la tolerancia adoptada, sin demostrar equivalencia predictiva.

Tabla 4: Selección de modelos: ajuste en entrenamiento y AUC en prueba.

Modelo	Variables	Parámetros	AIC	BIC	AUC
M1	Cuatro numéricas	5	8.639,72	8.674,46	0,7154
M2	Numéricas + importancia	7	8.629,41	8.678,05	0,7162
M3	Cuatro numéricas	5	8.639,72	8.674,46	0,7154

Coeficientes e interpretación. La tabla 5 presenta los coeficientes estandarizados y los OR por DE (o por categoría), con IC de Wald. Todos los términos incluidos tienen $p < 0{,}001$; estos valores son condicionales a la selección. En M2, importancia baja y media presentan menores odds de atraso que importancia alta (OR 0,722 y 0,692). Son asociaciones ajustadas, no efectos causales.

En unidades del negocio, manteniendo los demás predictores constantes, M1 estima un OR de **0,835 por 1.000 g** (IC 95 %: [0,804; 0,866]), equivalente a odds de atraso 16,5 % menores; por **10 unidades de descuento**, las odds se multiplican por **2,756** ([2,520; 3,013]). Por 10 USD de costo, el OR es 0,977 ([0,965; 0,988]); por una compra previa adicional, 0,927 ([0,893; 0,962]). Estas lecturas describen el modelo especificado, no cambios porcentuales de probabilidad; su interpretación definitiva requiere completar estabilidad y diagnóstico.

Tabla 5: Coeficientes y OR de los tres modelos. M1 y M3 tienen ajustes idénticos.

Modelo	Predictor	β	OR	IC 95 % del OR
M1/M3	Peso	-0,285	0,752	[0,710; 0,798]
M1/M3	Descuento	1,575	4,829	[4,204; 5,547]
M1/M3	Costo	-0,108	0,897	[0,850; 0,947]
M1/M3	Compras previas	-0,110	0,896	[0,849; 0,945]
M2	Peso	-0,293	0,746	[0,703; 0,791]
M2	Descuento	1,574	4,824	[4,198; 5,542]
M2	Costo	-0,108	0,897	[0,850; 0,947]
M2	Compras previas	-0,115	0,892	[0,845; 0,941]
M2	Importancia baja / alta	-0,325	0,722	[0,597; 0,875]
M2	Importancia media / alta	-0,369	0,692	[0,571; 0,838]

Desempeño. La tabla 6 y la figura 3 comparan entrenamiento y prueba. M1 obtiene AUC 0,7154 y exactitud 63,03 % en prueba. La clase mayoritaria alcanza exactitud 59,67 % y F1 74,74 %, superior al F1 de M1, pero especificidad cero: clasifica todos los envíos como atrasados. Por ello, M1 no mejora todas las métricas de la referencia.

Tabla 6: Métricas con umbral 0,5. Excepto AUC, valores porcentuales; entrenamiento: 7.699 envíos, prueba: 3.300.

Modelo	Conjunto	Exact.	Prec.	Sens.	F1	Espec.	AUC
M1	Entren.	63,14	69,57	67,94	68,74	56,04	0,7112
M1	Prueba	63,03	69,31	68,26	68,78	55,30	0,7154
M2	Entren.	63,33	69,79	67,98	68,87	56,46	0,7137
M2	Prueba	63,45	69,88	68,11	68,98	56,57	0,7162
M3	Entren.	63,14	69,57	67,94	68,74	56,04	0,7112
M3	Prueba	63,03	69,31	68,26	68,78	55,30	0,7154

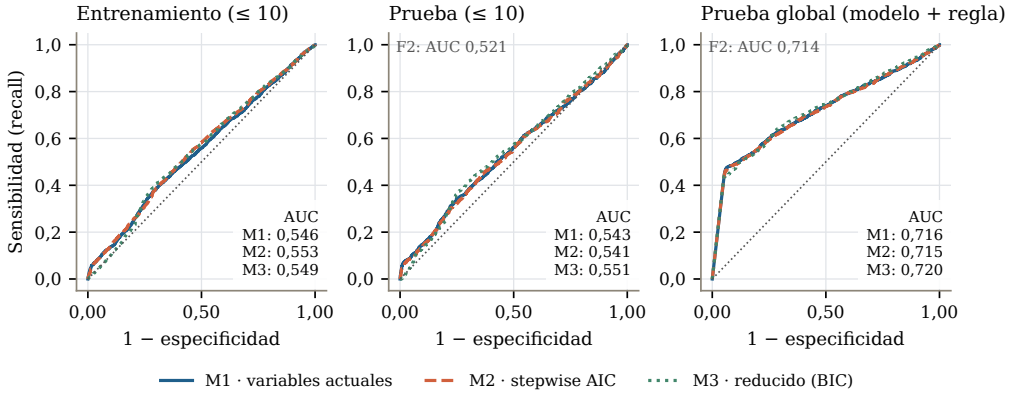


Figura 3: Curvas ROC en entrenamiento y prueba. Las curvas M1 y M3 coinciden; la diagonal representa ausencia de discriminación.

En prueba, M1 identifica 1.344 atrasos, omite 625 y genera 595 falsas alertas; reconoce correctamente 736 envíos puntuales. M2 reduce las falsas alertas a 578, pero omite 628 atrasos. El costo de M1 menos el de M2 es $17 - 3r$, donde r es el costo relativo FN:FP: M2 tiene menor costo en los escenarios $r = 1, 2, 5$, y M1 lo tendría para $r > 17/3$. Por tanto, la elección por parsimonia no garantiza menor costo operacional. Las matrices completas de ambos conjuntos se muestran en la figura 4.

Trazabilidad: tablas exportadas por el notebook en `sumativa_3/outputs/tablas/`: `modelos_resumen.csv`, `modelos_coeficientes_or.csv`, `modelos_metricas.csv` y `modelos_seleccion.csv`.

3.3 Estabilidad del modelo final

El coeficiente del modelo final es estable. El peso conserva su signo negativo en las 10.000 réplicas (tabla 7, figura 5). Su EE *bootstrap* difiere un 1,3 % del de Wald y su sesgo es despreciable

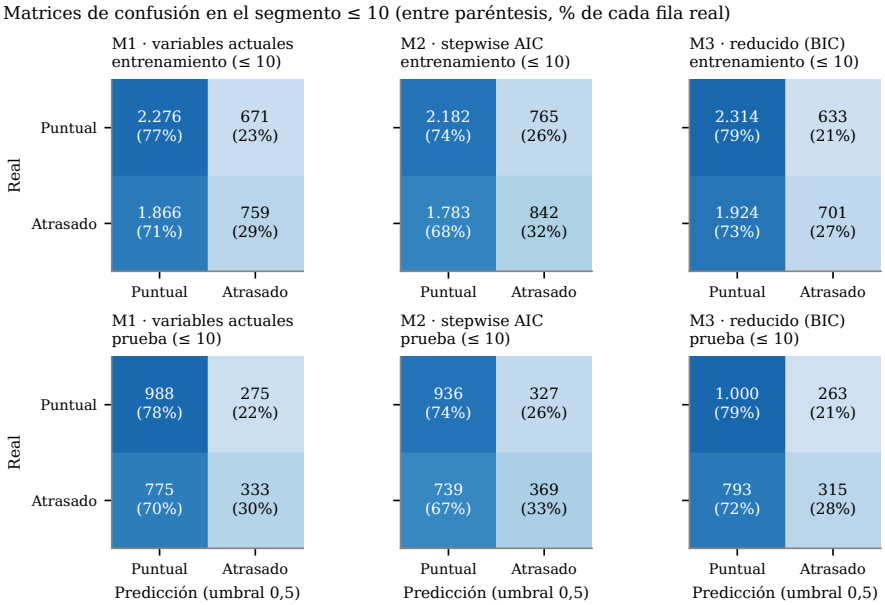


Figura 4: Matrices de confusión de los tres modelos, con clase 1 = atraso y clase 0 = entrega puntual. Filas: clase real; columnas: predicción.

(−0,0002). En unidades del negocio, cada 1.000 g adicionales multiplican las odds de atraso por **0,905** (IC BCa 95 %: [0,873; 0,937]), unas odds 9,5 % menores, prácticamente igual que el IC de Wald ([0,874; 0,936]).

Tabla 7: *Bootstrap* de los coeficientes estandarizados ($B = 10.000$; segmento ≤ 10). EE B/W: razón entre el EE *bootstrap* y el de Wald; signo: % de réplicas que lo conservan.

Modelo	Coeficiente	IC 95 % Wald	IC 95 % BCa	EE B/W	Signo	Estabilidad
M3 (final)	Peso	[−0,206; −0,101]	[−0,207; −0,100]	1,01	**100 %**	Estable
M1	Peso	[−0,256; −0,138]	[−0,256; −0,138]	1,00	100 %	Estable
M1	Compras previas	[−0,133; −0,021]	[−0,135; −0,022]	1,02	99,8 %	Estable
M1	Costo	[−0,112; 0,002]	[−0,111; 0,002]	1,00	97,1 %	Inestable
M1	Descuento	[−0,076; 0,030]	[−0,076; 0,030]	1,00	**79,9 %**	Inestable
M2	Importancia baja / alta	[−0,450; −0,051]	[−0,445; −0,047]	1,00	99,4 %	Estable
M2	Importancia media / alta	[−0,523; −0,123]	[−0,522; −0,120]	1,00	99,9 %	Estable

Los coeficientes inestables son los que S2 había marcado como sensibles. Dentro del segmento ≤ 10, el descuento cambia de signo en una de cada cinco réplicas: no tiene un efecto definido, lo que confirma con el modelo que su asociación con el atraso de S1 dependía del segmento > 10. El costo queda en el límite, con un IC que incluye el cero y el 97,1 % de conservación del signo (97,4 % en M2). Compras previas e importancia son estables, aunque de magnitud pequeña. En los tres modelos, el *bootstrap* coincide con Wald (EE a lo sumo un 3 % distintos), porque con más de 5.000 envíos la aproximación normal es adecuada, como en S2. Su aporte no es corregir los IC, sino mostrar qué coeficientes conservan el signo. El *bootstrap* remuestrea el dataset ya imputado, por lo que no incorpora la incertidumbre de la imputación ni la de la selección del modelo.

Trazabilidad: `bootstrap_coeficientes.csv`, `bootstrap_replicas_modelo_final.csv` y `modelos_preparacion.csv` (DE del peso en el entrenamiento: 1.527 g).

3.4 Diagnóstico del modelo final

(Pendiente.)

3.5 Impacto de la estrategia de imputación

(Pendiente.)

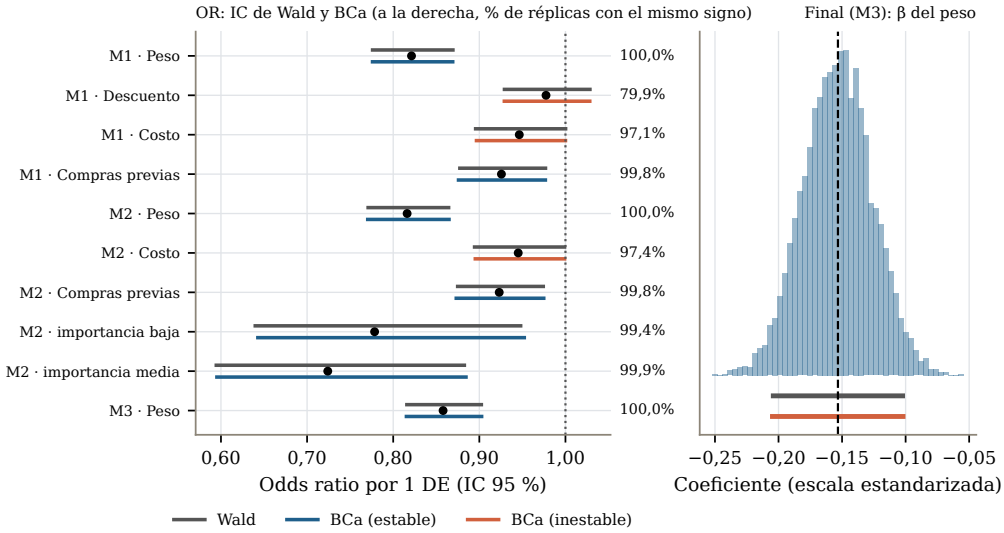


Figura 5: *Bootstrap* de los tres modelos. Izquierda: OR por 1 DE con IC de Wald y BCa, y porcentaje de réplicas que conservan el signo. Derecha: distribución *bootstrap* del coeficiente del peso en el modelo final (M3), con sus IC de Wald y BCa.

4. Discusión

(Pendiente.)

5. Conclusiones y recomendaciones

(Pendiente.)

Referencias

- Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Gopalani, P. (2021). *E-Commerce Shipping Data*, versión 1. Kaggle.
- Hosmer, D. W., Lemeshow, S. y Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.ª ed.). Wiley.
- Little, R. J. A. y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.