

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Cierre y Comunicación del Proyecto

Informe final integrado · 60 %

Título del proyecto:	Factores asociados al atraso en envíos de comercio electrónico: del análisis exploratorio a la clasificación
Integrantes:	José Ignacio Rodríguez, Yerko Gallardo Miranda y Sebastián Rojas Araya
Dataset:	*E-Commerce Shipping Data* (Gopalani, 2021), 10.999 envíos
Docente:	J. P. Maidana
Fecha:	28/10/2026
Repositorio GitHub:	`https://github.com/joserodriguezc/grupo_1_estadistica_computacional`

Resumen ejecutivo

Problema. El 59,67 % de los 10.999 envíos de una empresa de comercio electrónico llegó atrasado. El proyecto buscó qué características se asocian con el atraso y qué evidencia orienta una revisión operacional.

Enfoque. La Sumativa 1 (S1) describió e infirió las asociaciones; la Sumativa 2 (S2) las validó por remuestreo y simulación; y esta Sumativa 3 (S3) las modeló. Se simularon faltantes al azar condicionados a lo observado (10 %) en cuatro predictores y se compararon tres estrategias; la imputación por regresión lineal múltiple fue la más fiel a los valores reales. Siguiendo la retroalimentación de la Formativa 2 (F2), se ajustaron tres regresiones logísticas en el segmento con descuento ≤ 10 y se clasificó con una regla el segmento > 10, todo atrasado. La estabilidad se evaluó con *bootstrap* ($B = 10.000$).

Resultado principal. El modelo final usa **solo el peso**: cada 1.000 g adicionales reducen las odds de atraso un 9,5 % (OR 0,905; IC 95 % BCa [0,873; 0,937]), con el mismo signo en el 100 % de las réplicas. Dentro del segmento, el descuento no aporta. El clasificador combinado alcanza un AUC de 0,720 (0,714 en F2), pero en el segmento ≤ 10 solo 0,551 (0,521 en F2): fuera del descuento alto, los datos tienen poca señal.

Recomendación. Auditar los envíos con descuento mayor que 10, que concentran el atraso seguro, y revisar el proceso de los envíos livianos; usar el modelo solo como apoyo descriptivo para priorizar revisiones.

1. Introducción

Una empresa de comercio electrónico de productos electrónicos registró 10.999 envíos (Gopalani, 2021), de los cuales el **59,67 %** llegó atrasado (IC de Wilson al 95 %: [58,75; 60,58]). El proyecto se organizó en tres fases que se apoyan una en otra.

Sumativa 1 (S1): análisis exploratorio e inferencial. Preguntó *qué características se asocian con el atraso y qué evidencia orienta una revisión operacional.* Encontró que los envíos atrasados pesan en promedio 896 g menos que los puntuales ($d_{av} = -0{,}57$) y reciben 13,1 unidades más de descuento ($d_{av} = 0{,}96$), mientras que la modalidad de envío no se asocia con el atraso (p de Holm = 0,69). Recomendó auditar los 2.647 envíos con descuento mayor que 10, todos atrasados.

Sumativa 2 (S2): validación por remuestreo y simulación. Confirmó los intervalos y las decisiones de S1 con *bootstrap* y permutación ($B = 10.000$). Sus escenarios de sensibilidad mostraron que **el peso es la única asociación robusta**: la del descuento existe solo por el segmento con descuento mayor que 10, y el *jackknife* reveló que ese segmento coincide con los envíos 1 a 3.135 del archivo. La Formativa 2 ensayó una regresión logística con esos hallazgos: alcanzó un área bajo la curva ROC (AUC) de 0,714, pero de solo 0,52 en los envíos con descuento ≤ 10.

Sumativa 3 (S3): modelamiento. Esta fase pasa de describir asociaciones a **clasificar el atraso**. Cada decisión se fundamenta en un resultado de S1 o de S2:

- manejo de datos faltantes, con imputación por regresión lineal múltiple y comparación de estrategias;
- tres modelos de regresión logística en el segmento con descuento ≤ 10 (variables de S1 y S2, *stepwise* por AIC y reducido por BIC), con una regla para el segmento > 10, todo atrasado;
- estabilidad de los coeficientes por *bootstrap* y diagnóstico de supuestos;
- impacto de la estrategia de imputación sobre el modelo final.

La sección 2 describe la metodología integrada, la 3 presenta los resultados, la 4 los discute y la 5 formula las recomendaciones.

2. Metodología integrada

2.1 Datos, trazabilidad y punto de partida

Datos y reproducibilidad. Antes de usar el CSV original de S1, el notebook maestro verifica su huella SHA-256; el archivo se lee desde `sumativa_1/data/raw/`, sin copiarlo. Las cifras de S1, S2 y la Formativa 2 se leen desde sus tablas publicadas, sin recalcularse. Toda la aleatoriedad usa la semilla de S2 (`1505514103`), obtenida del pulso 1.053.589 del faro de aleatoriedad de la Universidad de Chile. De `SeedSequence(SEMILLA).spawn(10)` se derivan flujos independientes: los siete primeros son los de S2, el octavo es el de la Formativa 2, el noveno simula los faltantes y el décimo alimenta el *bootstrap* de S3.

Partición común. La partición 70/30, estratificada por el atraso, se define una sola vez sobre los 10.999 envíos: 7.699 de entrenamiento y 3.300 de prueba, ambos con 59,67 % de atraso. Es la misma de la Formativa 2. Todas las estrategias de imputación y todos los modelos usan esos mismos envíos, de modo que las diferencias entre resultados no dependen del azar de la partición. La preparación, el ajuste y las métricas usan funciones compartidas; con los datos completos, reproducen el AUC de la Formativa 2 (0,721).

Punto de partida. S1 registró **cero valores faltantes** en las 12 variables, por lo que el análisis de faltantes parte de un 0 % sin patrón. Las relaciones entre las variables numéricas son débiles: ningún $|\rho|$ de Spearman supera 0,32 (figura 1). S2 distinguió dos grupos. El bloque peso–costo–compras previas–llamadas es **estable**: sus seis correlaciones excluyen el cero en los cuatro escenarios de sensibilidad. Las cuatro correlaciones del descuento son **inestables**: se anulan al retirar el segmento con descuento mayor que 10. La tabla 1 resume cómo estos hallazgos orientan cada decisión de S3.

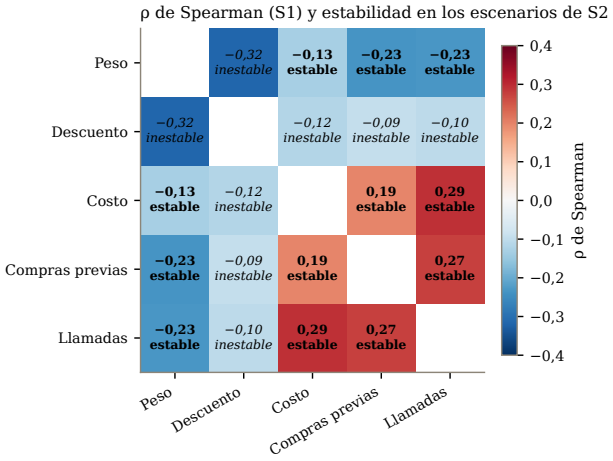


Figura 1: Correlaciones de Spearman entre las variables numéricas (S1) y su estabilidad en los cuatro escenarios de sensibilidad de S2. En negrita, las que excluyen el cero en todos los escenarios.

Tabla 1: Hallazgos de S1 y S2 que fundamentan las decisiones de S3.

Hallazgo previo	Fuente	Decisión en S3
Ningún valor faltante en 10.999 envíos	S1	Simular faltantes con un mecanismo conocido para ejercitar la imputación
Matriz de Spearman entre variables numéricas	S1	Origen de los predictores de cada regresión de imputación
Bloque peso–costo–compras–llamadas estable; descuento inestable	S2	Priorizar predictores estables al imputar
Extremos IQR válidos; winsorizar no cambia nada y excluir cambia la población	S1, S2	Conservar los outliers
Peso robusto; descuento dependiente del segmento > 10 (100 % atrasado); costo y compras débiles	S1, S2, F2	Modelos en el segmento ≤ 10 y regla para > 10; variables del modelo basado en S1 y S2
Modalidad sin asociación (T01)	S1, S2	Candidata solo para la selección automática
Llamadas y calificación posiblemente posteriores a la entrega	S1	Excluidas como predictores del atraso
Envíos 1 a 3.135 todos atrasados	S2	Excluir el identificador (fuga de información)
IC percentil y BCa validados con $B = 10.000$	S2	Mismo método para la estabilidad del modelo final

2.2 Datos faltantes e imputación por regresión

Simulación de faltantes (S1 → S3). Como S1 no registró faltantes, se eliminó cerca del 10 % de los valores de las cuatro variables numéricas candidatas a predictor (peso, costo, compras previas y descuento) mediante un mecanismo **de faltantes al azar condicionados a lo observado (MAR)**, declarado de antemano. La probabilidad de faltar es una función logística de variables completas (importancia, bodega, modalidad y género), con efectos distintos para cada variable y un intercepto calibrado para una tasa media del 10 %. Por diseño, el mecanismo no depende del valor propio, lo que lo haría no aleatorio (MNAR), ni del atraso, para no contaminar la evaluación posterior. El mecanismo se verificó con una regresión logística del indicador de faltante: la prueba de razón de verosimilitud (LR) sobre las variables observadas contrasta la hipótesis de faltantes completamente al azar (MCAR), y el coeficiente del valor propio contrasta la de MNAR.

Imputación por regresión lineal múltiple (S1 y S2 → S3). Se ajustó una regresión por variable, por mínimos cuadrados con sus casos completos. Los predictores se tomaron de la matriz de Spearman de S1 con una regla explícita: se incluyen las correlaciones estables en los cuatro escenarios de S2, se agregan las inestables con $|\rho| \geq 0{,}30$ y, si quedan menos de tres, se usan todas las candidatas. Así, el peso se imputa con descuento, compras previas, llamadas y costo; el costo y las compras previas, con sus tres correlatos estables; y el descuento, sin ninguna correlación estable en S2, con las cuatro candidatas. El atraso nunca es predictor. Se evaluaron los supuestos de linealidad, homocedasticidad (Breusch-Pagan), normalidad (Jarque-Bera), independencia (Durbin-Watson) y multicolinealidad (VIF), y el desempeño mediante R^2 y la raíz del error cuadrático medio (RMSE) con validación cruzada de 5 particiones. Cuando un predictor también faltaba, se completó provisionalmente con su mediana; las predicciones se recortaron al rango observado y se redondearon, porque las cuatro variables son enteras.

Comparación de estrategias. La imputación por regresión se comparó con la eliminación de filas incompletas y con la imputación por la mediana, con cinco criterios: (a) tamaño resultante; (b) distribución frente a los datos originales (media, DE y prueba de Kolmogorov-Smirnov, KS); (c) preservación de las correlaciones de Spearman de S1; (d) error frente al **valor real**, que se conoce porque los faltantes son simulados; y (e) asignación al segmento de descuento de S1 (> 10, todo atrasado), que la Parte 2 usa para separar el modelo de la regla.

2.3 Regresión logística: segmentación, modelos y evaluación

Segmentación por el descuento (S1, S2 y F2 → S3). S1 mostró que los 2.647 envíos con descuento > 10 están todos atrasados, y S2, que la asociación del descuento con el atraso existe

solo por ese segmento; en la Formativa 2 (F2), fuera de él, el modelo discriminó como el azar (AUC 0,521). Un indicador "descuento > 10" produciría separación completa: su coeficiente de máxima verosimilitud no existe. Por eso, siguiendo la retroalimentación de F2, los tres modelos se ajustan en el **segmento** ≤ 10, donde está la incertidumbre real, y el segmento > 10 se clasifica con una **regla**: probabilidad igual a su tasa de atraso en el entrenamiento. El **clasificador combinado** (modelo más regla) se evalúa sobre todos los envíos, para compararlo con el AUC de 0,714 de F2. El segmento se asigna con el descuento del dataset imputado por regresión.

Preparación. Se usa la partición común de la sección 2.1. Se conservan los extremos, válidos según S1 y sin efecto al winsorizar según S2. Las numéricas se estandarizan con la media y la desviación estándar (DE) del entrenamiento del segmento, y las categóricas se codifican con indicadores, con el primer nivel como referencia. Se excluyen el identificador, por la estructura del archivo detectada en S2, y llamadas y calificación, porque pueden registrarse después de la entrega. No se ponderan las clases: en el segmento el atraso es cercano al 47 %, y ponderar solo movería el equilibrio entre sensibilidad y especificidad.

Tres modelos. M1 (variables actuales) usa peso, descuento, costo y compras previas, las de F2, elegidas por sus correlaciones de S1 validadas en S2. **M2 (*stepwise* por AIC)** parte del intercepto y en cada paso agrega o quita la variable que más reduce el criterio de información de Akaike (AIC), entre las cuatro numéricas y las cuatro categóricas (importancia, bodega, modalidad y género); las categóricas entran y salen completas. **M3 (reducido)** es el subconjunto de mínimo criterio de información bayesiano (BIC) entre los 256 posibles, que penaliza más la complejidad. Los tres se ajustan por máxima verosimilitud con el entrenamiento del segmento, y se reportan los coeficientes y las razones de odds (OR) con IC de Wald al 95 %, por DE y en unidades del negocio.

Evaluación y elección. Con umbral 0,5 se calculan matrices de confusión, exactitud, precisión, sensibilidad, F1, especificidad y AUC, en entrenamiento y prueba, en el segmento y en el clasificador combinado; la referencia es la clase mayoritaria. Son candidatos los modelos a no más de 0,005 del mayor AUC de prueba en el segmento, y entre ellos se elige el menor BIC. Esta tolerancia es una regla práctica, no una prueba de equivalencia. Como la prueba participa en la elección y la imputación se ajustó antes de separar los conjuntos, la evaluación es exploratoria; una sensibilidad reajusta la imputación solo con el entrenamiento. Los IC son condicionales al modelo elegido y al dataset imputado.

2.4 Estabilidad y diagnóstico

Estabilidad por *bootstrap* (S2 → S3). Con el mismo método que S2 validó, se aplicó un *bootstrap* no paramétrico por pares a los coeficientes: $B = 10.000$ remuestras con reemplazo de los 5.572 envíos de entrenamiento del segmento ≤ 10, con el flujo de semilla reservado para S3. En cada remuestra se reajustaron los tres modelos con las mismas filas. Para cada coeficiente se calcularon los IC 95 % percentil y BCa (aceleración por *jackknife*), comparados con el IC de Wald; la razón entre el error estándar (EE) *bootstrap* y el de Wald, y el **porcentaje de réplicas que conservan el signo** de la estimación. Un coeficiente se considera **inestable** si su IC BCa incluye el cero (el de su OR incluye el 1), si conserva el signo en menos del 97,5 % de las réplicas o si su EE *bootstrap* supera en más de un 20 % al de Wald.

Diagnóstico. Se evaluaron la multicolinealidad con el factor de inflación de la varianza (VIF), con 5 y 10 como referencias de revisión; la linealidad en el logit con la prueba de Box-Tidwell (término $x \log x$ para las numéricas positivas, con ajuste de Holm) y con el logit empírico por deciles; la influencia con el modelo lineal generalizado binomial equivalente, marcando una alerta si la distancia de Cook supera $4/n$, el *leverage* supera $2p/n$ o algún |DFBETAS| supera $2/\sqrt{n}$; y los residuos de *deviance*, de Pearson y agrupados en 20 grupos de probabilidad, con su banda del 95 %. Las alertas de influencia orientan una sensibilidad, no la eliminación de envíos válidos.

3. Resultados integrados

3.1 Datos faltantes e imputación

Faltantes simulados. Cada variable perdió entre el 9,6 % y el 10,1 % de sus valores (tabla 2); 3.786 envíos (34,4 %) tienen al menos un faltante y quedan 7.213 casos completos. El mecanismo es MAR: la prueba LR rechaza MCAR en las cuatro variables (χ^2_9 entre 128,4 y 174,2; $p < 0{,}001$), mientras que el valor propio no aporta una vez controladas las observadas (p entre 0,17 y 0,65).

Tabla 2: Faltantes simulados y desempeño de las regresiones de imputación (R^2 y RMSE con validación cruzada de 5 particiones).

Variable	Faltantes	%	Predictores	n de ajuste	R^2	RMSE / DE
Peso	1.086	9,87	Descuento, compras, llamadas, costo	7.213	0,272	0,85
Costo	1.107	10,06	Llamadas, compras, peso	8.043	0,111	0,94
Compras previas	1.055	9,59	Llamadas, peso, costo	8.043	0,054	0,97
Descuento	1.112	10,11	Peso, costo, llamadas, compras	7.213	0,217	0,88

Regresiones de imputación. Como anticipaban las correlaciones débiles de S1 ($|\rho| \leq 0{,}32$), la capacidad predictiva es modesta: el RMSE equivale al 85–97 % de la DE de cada variable. El R^2 de validación cruzada coincide con el de ajuste, por lo que no hay sobreajuste, y todos los coeficientes tienen el signo de la ρ de S1. Jarque-Bera y Breusch-Pagan rechazan normalidad y homocedasticidad, esperable en variables discretas y acotadas, pero ambas violaciones afectan a los errores estándar y no a la predicción puntual que usa la imputación. Durbin-Watson indica autocorrelación en peso (1,01) y descuento (1,33), coherente con el orden del archivo que detectó S2; el VIF máximo es 1,21. Se imputaron 4.360 valores; entre 189 y 282 por variable usaron un predictor provisional y 29 predicciones se recortaron al rango observado.

Tabla 3: Comparación de las tres estrategias. En negrita, el mejor valor de cada criterio.

Criterio	Eliminación	Mediana	Regresión
(a) Envíos conservados	7.213	**10.999**	**10.999**
(a) Entrenamiento / prueba	5.058 / 2.155	**7.699 / 3.300**	**7.699 / 3.300**
(b) KS medio frente al original	**0,004**	0,048	0,030
(b) DE relativa media	**1,00**	0,95	0,96
(c) Máx. $\lvert\Delta\rho\rvert$ entre numéricas (S1)	**0,012**	0,027	0,043
(c) Máx. $\lvert\Delta\rho\rvert$ con el atraso (S1)	**0,006**	0,023	0,012
(d) RMSE / DE frente al valor real	—	1,05	**0,92**
(e) Envíos en el segmento equivocado	**0**	268	447
(e) Atraso en el segmento > 10 (S1: 100 %)	**100 %**	**100 %**	92,6 %

Comparación y decisión. La tabla 3 y la figura 2 muestran un compromiso:

- La **eliminación** conserva distribuciones, correlaciones y segmentos, porque las variables que generan los faltantes se relacionan poco con las numéricas. A cambio, pierde el 34,4 % de los envíos y reduce el entrenamiento a 5.058.
- La **mediana** es la peor en casi todos los criterios. Atenúa la correlación del descuento con el atraso (0,313 frente a 0,335 en S1) y, al imputar el descuento con 7, lleva al segmento ≤ 10 a 268 envíos con descuento real > 10, todos atrasados.
- La **regresión** conserva la muestra completa y tiene el menor error frente al valor real. Mantiene la relación con el atraso de los dos predictores principales de S1: descuento (0,333) y peso ($-0{,}265$ frente a $-0{,}266$). Su costo es el de toda imputación determinista: reduce la variabilidad, acentúa la correlación peso–descuento ($-0{,}316 \rightarrow -0{,}359$) y, al predecir descuentos cerca de la media, desplaza al segmento > 10 a 428 envíos con descuento real ≤ 10.

Se eligió la **imputación por regresión**, con esa limitación explícita, y la eliminación quedó como referencia de sensibilidad; su efecto en el modelo final se cuantifica en la sección 3.5.

Trazabilidad: `faltantes_resumen_variables.csv`, `faltantes_verificacion_mar.csv`, `imputacion_modelos.csv`, `imputacion_conteo.csv` y `estrategias_resumen.csv`.

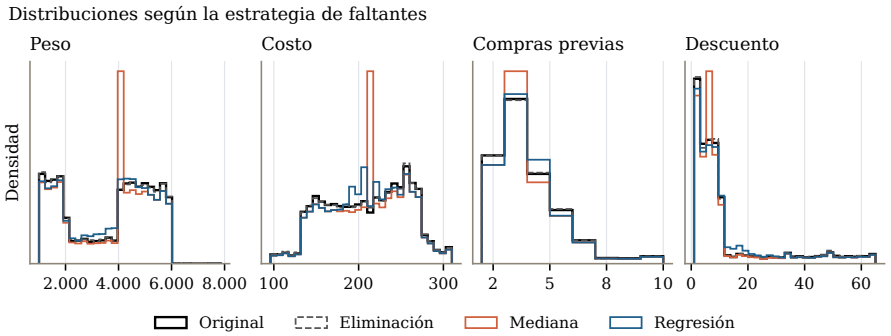


Figura 2: Distribución de cada variable según la estrategia de faltantes, frente a los datos originales.

3.2 Modelos logísticos y desempeño

Segmentación. El entrenamiento tiene 5.572 envíos con descuento ≤ 10 (47,1 % de atraso) y 2.127 con descuento > 10; la prueba, 2.371 y 929. Con el descuento imputado, la tasa de atraso del segmento > 10 es 92,6 % y no el 100 % de S1, por la asignación descrita en la sección 3.1.

Especificaciones. El *stepwise* por AIC incorporó, en orden, peso, compras previas, importancia y costo; nunca incluyó el descuento ni la modalidad, coherente con S1 (T01). El mínimo BIC conservó **solo el peso**, la única asociación robusta en todos los escenarios de S2 (tabla 4).

Tabla 4: Modelos en el segmento ≤ 10 (entrenamiento, $n = 5.572$) y AUC de prueba frente a F2.

					AUC de prueba	
Modelo	Variables	Parám.	AIC	BIC	≤ 10	Combinado
F2 (referencia)	Las de M1, sin segmentar	—	—	—	0,521	0,714
M1	Peso, descuento, costo, compras	5	7.671,0	7.704,2	0,543	0,716
M2	Peso, compras, importancia, costo	6	**7.663,6**	7.703,4	0,541	0,715
M3	Peso	2	7.677,3	**7.690,5**	**0,551**	**0,720**

Coeficientes. Dentro del segmento, el **descuento deja de aportar**: en M1 su OR por unidad es 0,992 (IC 95 %: [0,974; 1,010]; $p = 0{,}40$), y el costo queda en el límite (OR por 10 USD 0,988; $p = 0{,}06$). Manteniendo constantes los demás predictores, cada 1.000 g adicionales reducen las odds de atraso un 12,1 % en M1 (OR 0,879 [0,846; 0,914]) y un **9,5 % en M3** (OR **0,905** [0,874; 0,936]); cada compra previa adicional, un 5,2 % (OR 0,948 [0,913; 0,985], M1). En M2, la importancia baja y la media tienen odds de atraso un 22 % y un 28 % menores que la alta (OR 0,778 [0,638; 0,950] y 0,724 [0,593; 0,885]), coherente con la prueba E2 de S1.

Selección del modelo final: M3. Es el único a no más de 0,005 del mayor AUC de prueba del segmento y tiene el menor BIC. La diferencia de AUC entre modelos (0,010) es pequeña y no prueba superioridad; lo decisivo es que M3 logra lo mismo con un solo predictor, el más robusto de S1 y S2. No minimiza todos los costos: con un costo relativo FN:FP de 1, M1 tiene el menor costo en el segmento (1.050 frente a 1.056), y con 2 y 5, M2 (1.805 y 4.022 frente a 1.849 y 4.228).

Desempeño frente a F2. En el segmento ≤ 10, el AUC sube de **0,521 a 0,551** y la exactitud pasa de 0,508, bajo la clase mayoritaria, a 0,555, sobre su 0,533. En el clasificador combinado, el AUC sube de **0,714 a 0,720** y la exactitud, de 0,628 a 0,659 (figura 3). En la prueba, el clasificador combinado con M3 identifica 1.176 atrasos, omite 793, genera 331 falsas alertas y reconoce 1.000 envíos puntuales: precisión 0,780, sensibilidad 0,597, F1 0,677 y especificidad 0,751, frente a 0,538 en F2. Dentro del segmento, con probabilidades cercanas a 0,5, el modelo es conservador: sensibilidad 0,284 y especificidad 0,792. El F1 de la clase mayoritaria (0,747) es mayor, pero esa regla no distingue ningún envío puntual.

Trazabilidad: `modelos_segmentos.csv`, `modelos_stepwise.csv`, `modelos_resumen.csv`, `modelos_coeficientes_or.csv`, `modelos_metricas.csv`, `modelos_metricas_combinadas.csv`, `modelos_seleccion.csv` y `modelos_comparacion_f2.csv`.

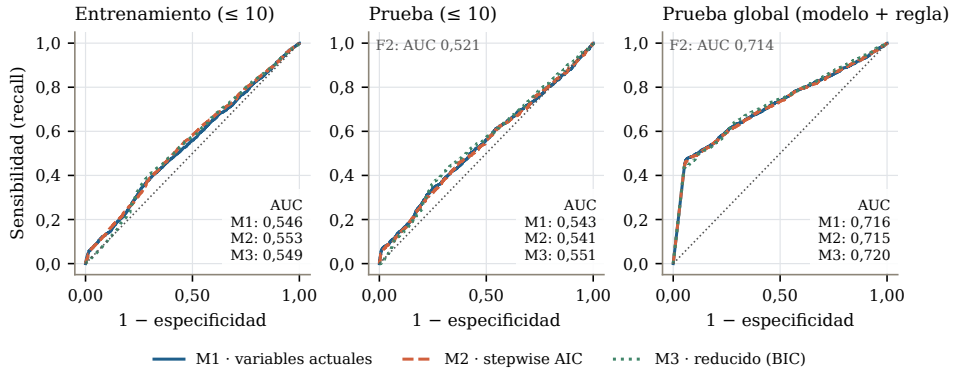


Figura 3: Curvas ROC de los tres modelos: en el segmento ≤ 10 (entrenamiento y prueba) y en el clasificador combinado sobre la prueba completa, con los AUC de referencia de F2.

3.3 Estabilidad del modelo final

El coeficiente del modelo final es estable. El peso conserva su signo negativo en las 10.000 réplicas (tabla 5, figura 4). Su EE *bootstrap* difiere un 1,3 % del de Wald y su sesgo es despreciable (−0,0002). En unidades del negocio, cada 1.000 g adicionales multiplican las odds de atraso por **0,905** (IC BCa 95 %: [0,873; 0,937]), unas odds 9,5 % menores, prácticamente igual que el IC de Wald ([0,874; 0,936]).

Tabla 5: *Bootstrap* de los coeficientes estandarizados ($B = 10.000$; segmento ≤ 10). EE B/W: razón entre el EE *bootstrap* y el de Wald; signo: % de réplicas que lo conservan.

Modelo	Coeficiente	IC 95 % Wald	IC 95 % BCa	EE B/W	Signo	Estabilidad
M3 (final)	Peso	[−0,206; −0,101]	[−0,207; −0,100]	1,01	**100 %**	Estable
M1	Peso	[−0,256; −0,138]	[−0,256; −0,138]	1,00	100 %	Estable
M1	Compras previas	[−0,133; −0,021]	[−0,135; −0,022]	1,02	99,8 %	Estable
M1	Costo	[−0,112; 0,002]	[−0,111; 0,002]	1,00	97,1 %	Inestable
M1	Descuento	[−0,076; 0,030]	[−0,076; 0,030]	1,00	**79,9 %**	Inestable
M2	Importancia baja / alta	[−0,450; −0,051]	[−0,445; −0,047]	1,00	99,4 %	Estable
M2	Importancia media / alta	[−0,523; −0,123]	[−0,522; −0,120]	1,00	99,9 %	Estable

Los coeficientes inestables son los que S2 había marcado como sensibles. Dentro del segmento ≤ 10, el descuento cambia de signo en una de cada cinco réplicas: no tiene un efecto definido, lo que confirma con el modelo que su asociación con el atraso de S1 dependía del segmento > 10. El costo queda en el límite, con un IC que incluye el cero y el 97,1 % de conservación del signo (97,4 % en M2). Compras previas e importancia son estables, aunque de magnitud pequeña. En los tres modelos, el *bootstrap* coincide con Wald (EE a lo sumo un 3 % distintos), porque con más de 5.000 envíos la aproximación normal es adecuada, como en S2. Su aporte no es corregir los IC, sino mostrar qué coeficientes conservan el signo. El *bootstrap* remuestrea el dataset ya imputado, por lo que no incorpora la incertidumbre de la imputación ni la de la selección del modelo.

Trazabilidad: `bootstrap_coeficientes.csv`, `bootstrap_replicas_modelo_final.csv` y `modelos_preparacion.csv` (DE del peso en el entrenamiento: 1.527 g).

3.4 Diagnóstico del modelo final

Multicolinealidad. Los VIF de las variables numéricas no superan 1,26 en ningún modelo, como en F2 (1,25). Los indicadores de importancia de M2 llegan a 3,6 porque comparten la categoría de referencia (alta, 8,6 % de los envíos); no es colinealidad entre predictores distintos. Dentro del segmento, la correlación peso–descuento es prácticamente nula (−0,005), por lo que desaparece la confusión entre ambos que tenía el modelo global.

Linealidad en el logit. Box-Tidwell rechaza la linealidad del peso (razón de verosimilitud 23,9 con 1 gl; $p < 0{,}001$), coherente con su distribución bimodal en S1. El logit empírico por deciles (figura 5) muestra un efecto no monótono: el atraso es máximo cerca de 3.000 g, y la recta del

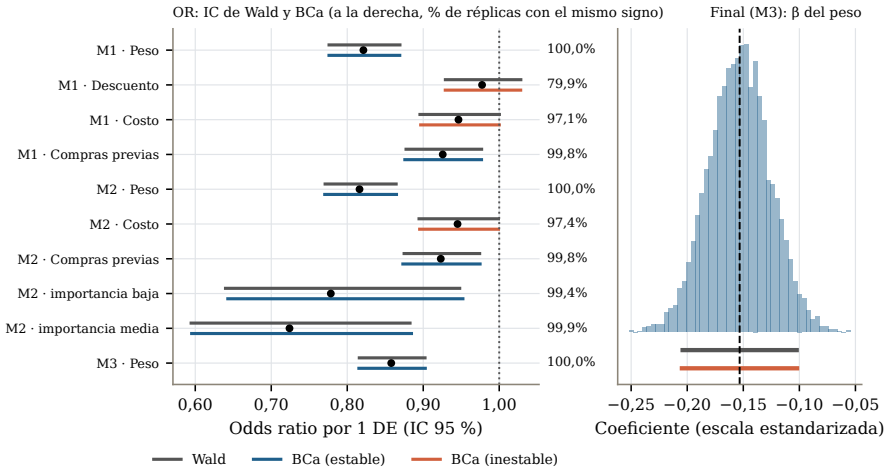


Figura 4: *Bootstrap* de los tres modelos. Izquierda: OR por 1 DE con IC de Wald y BCa, y porcentaje de réplicas que conservan el signo. Derecha: distribución *bootstrap* del coeficiente del peso en el modelo final (M3), con sus IC de Wald y BCa.

modelo solo captura la tendencia descendente. Los residuos agrupados lo confirman: 7 de los 20 grupos quedan fuera de la banda del 95 %, cuando por azar se esperaría uno, y los mayores residuos positivos (+0,15 a +0,18) están en las probabilidades de 0,47 a 0,52, que corresponden a esos pesos.

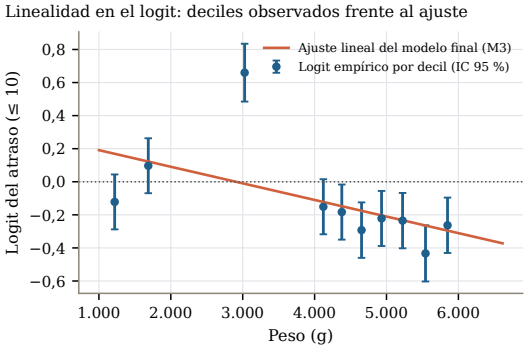


Figura 5: Logit empírico del atraso por deciles de peso (IC 95 %) frente al ajuste lineal de M3, en el segmento ≤ 10.

Influencia y sensibilidad. 523 de los 5.572 envíos tienen alguna alerta: todos por *leverage*, porque son los pesos más extremos, y 177 además por DFBETAS; ninguno supera el umbral de Cook. Sin ellos, el OR del peso por 1.000 g pasa de 0,905 a 0,853: misma dirección, más intenso. Se conservan, porque son envíos válidos. Reajustar la imputación solo con el entrenamiento (AUC 0,551) o asignar el segmento con el descuento original (AUC 0,551) no cambia el resultado.

Trazabilidad: `modelos_vif.csv`, `modelos_box_tidwell_conjunto.csv`, `modelos_logit_empirico.csv`, `modelos_residuos_agrupados.csv`, `modelos_influencia_resumen.csv`, `modelos_sensibilidad_influencia.csv` y `modelos_sensibilidad_evaluacion.csv`.

3.5 Impacto de la estrategia de imputación

M3 se reajustó con cada dataset de la Parte 1 y con los **datos originales sin faltantes**, con el mismo flujo: partición común, segmento según el descuento de cada dataset y regla para > 10. Como los faltantes son simulados, todos los modelos se evaluaron además en una **prueba común con valores reales** (los mismos 3.300 envíos, con sus valores y segmentos originales), de modo que las diferencias de desempeño se deben solo a los coeficientes.

¿Cambian las conclusiones? No en dirección, significancia ni capacidad de ordenar los envíos:

Tabla 6: M3 según la estrategia de faltantes: segmento, OR del peso por 1.000 g (IC 95 % de Wald) y AUC del clasificador combinado en la prueba propia y en la común.

	Entren.	Segmento		Dif. con	AUC combinado	
Estrategia	≤ 10	equivocado	OR del peso	el original	Propia	Común
Eliminación	3.840	0	0,899 [0,865; 0,936]	−0,4 %	0,733	0,736
Mediana	6.043	268	0,873 [0,844; 0,902]	**−3,4 %**	0,729	0,736
Regresión	5.572	447	**0,905** [0,874; 0,936]	**+0,1 %**	0,720	0,736
Original	5.859	—	0,903 [0,875; 0,933]	—	0,736	0,736

el peso es negativo y significativo con las cuatro opciones, y en la prueba común el AUC es idéntico (0,553 en el segmento y 0,736 combinado). Sí cambian dos aspectos (tabla 6, figura 6):

- **La magnitud del efecto del peso**, sesgada solo por la mediana: al llevar al segmento ≤ 10 a 268 envíos con descuento real > 10, todos atrasados, su OR se aleja un 3,4 % del original, que queda fuera de su IC. La regresión (+0,1 %) y la eliminación (−0,4 %) lo reproducen, y la regresión da un IC un 12 % más estrecho que la eliminación.
- **La asignación del segmento**, que con la regresión reduce el AUC combinado en la prueba propia (0,720 frente a 0,736): la regla clasifica como atrasados a los 428 envíos con descuento real ≤ 10 que la imputación llevó sobre 10. El costo está en la regla, no en el modelo.

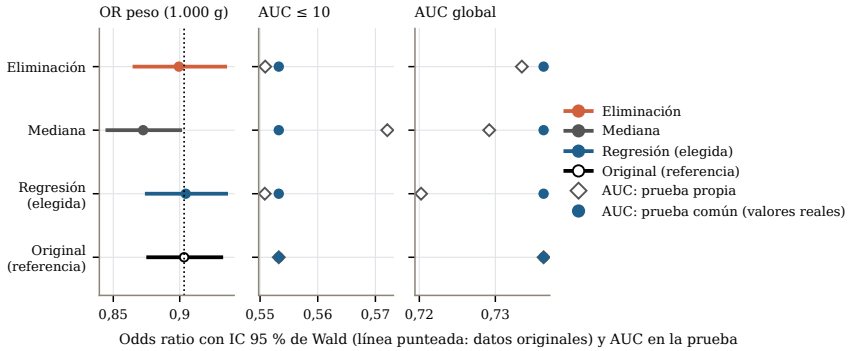


Figura 6: OR del peso por 1.000 g (IC 95 %; línea punteada: datos originales) y AUC en el segmento y en el clasificador combinado, según la estrategia de faltantes, en la prueba propia y en la prueba común con valores reales.

Trazabilidad: `impacto_imputacion_segmento.csv`, `impacto_imputacion_coeficientes.csv` e `impacto_imputacion_desempeno.csv`.

4. Discusión

Qué confirma S3 de S1 y S2. El modelamiento llega, por un camino distinto, a la misma jerarquía de evidencia:

- **El peso es el factor robusto.** Es la única variable del modelo de mínimo BIC, conserva su signo en el 100 % de las réplicas *bootstrap*, mantiene su efecto con las tres estrategias de faltantes y sobrevive a las alertas de influencia.
- **El descuento importa solo como umbral.** Sobre 10 determina el atraso en S1; bajo 10 su OR es 0,992 ($p = 0{,}40$) y cambia de signo en una de cada cinco réplicas. Esto explica por qué la F2 discriminaba como el azar fuera de ese segmento.
- **La modalidad no se asocia con el atraso** (T01 de S1): ningún procedimiento de selección la incorporó. Importancia, compras previas y costo tienen efectos pequeños y, el costo, inestables.

Límites.

- **Poca señal fuera del descuento alto.** En el segmento ≤ 10 el mejor AUC es 0,551, apenas sobre el 0,521 de F2.

- **Forma funcional del peso.** El efecto es no monótono, con un máximo de atraso cerca de 3.000 g, y el modelo lineal solo captura la tendencia. Los OR describen esa tendencia, no un efecto constante en todo el rango.
- **El segmento > 10 podría ser un artefacto de registro.** S2 mostró que coincide con los envíos 1 a 3.135 del archivo. La regla funciona en estos datos, pero si el segmento refleja la forma en que se armó el archivo y no una política de descuentos, no se trasladaría a envíos nuevos.
- **Faltantes simulados.** El mecanismo MAR es conocido y moderado; con faltantes reales, el mecanismo es desconocido y podría ser MNAR. La imputación por regresión es determinista: reduce la variabilidad y no propaga su incertidumbre a los IC, algo que haría la imputación múltiple. Además, al imputar una variable con efecto de umbral, desplazó envíos entre segmentos, un efecto que las métricas habituales de imputación no anticipaban.
- **Evaluación exploratoria.** La prueba participó en la elección del modelo y la imputación se ajustó antes de separar los conjuntos (sin efecto en el AUC, según la sensibilidad); los IC no incorporan la incertidumbre de la selección.
- **Causalidad y validez externa.** Los datos son observacionales, de una sola fuente y sin fechas: los OR son asociaciones, sin validez probada para otros períodos o empresas.

5. Conclusiones y recomendaciones

Respuesta a la pregunta de S1. El atraso se asocia sobre todo con dos características: un **descuento mayor que 10**, que en estos datos implica atraso en el 100 % de los casos, y, fuera de ese segmento, un **menor peso**, cuyo efecto es el único robusto a todas las validaciones de S2 y S3. Las demás variables tienen efectos pequeños, inestables o nulos.

Recomendaciones para la empresa:

1. **Auditar los envíos con descuento mayor que 10** (24 % de los envíos), como propuso S1: verificar si el descuento es una compensación posterior al atraso, una política comercial o un efecto de cómo se registraron los envíos 1 a 3.135. Es la acción con mayor potencial y la que define si la regla sirve para envíos futuros.
2. **Revisar el proceso de los envíos livianos**, en especial los cercanos a 3.000 g, donde el atraso es máximo dentro del segmento ≤ 10.
3. **Usar el clasificador combinado (M3 más la regla) solo como apoyo descriptivo para priorizar revisiones**, no como predictor operacional: identifica el 59,7 % de los atrasos con un 78 % de precisión, pero dentro del segmento ≤ 10 su capacidad de discriminación es baja (AUC 0,551).
4. **Mejorar el registro**: fechas, transportista, distancia y el momento en que se registran llamadas y calificación.

Recomendaciones para un análisis futuro: modelar la forma no lineal del peso (por tramos o con *splines*); validar con envíos nuevos; fijar los costos reales de cada tipo de error para elegir el umbral; y, con faltantes reales, usar imputación múltiple e imputar la pertenencia al segmento de descuento en lugar de su valor continuo.

Referencias

- Box, G. E. P. y Tidwell, P. W. (1962). Transformation of the independent variables. *Technometrics*, 4(4), 531–550.
- Efron, B. (1987). Better bootstrap confidence intervals. *JASA*, 82(397), 171–185.
- Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Gopalani, P. (2021). *E-Commerce Shipping Data*, versión 1. Kaggle.
- Hosmer, D. W., Lemeshow, S. y Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.ª ed.). Wiley.
- Little, R. J. A. y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.
- Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.