

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

# Evaluación Sumativa 3

Cierre y Comunicación del Proyecto

*Informe final integrado · 60 %*

| | |
|---|---|
| **Título del proyecto:** | Factores asociados al atraso en envíos de comercio electrónico: del análisis exploratorio a la clasificación |
| **Integrantes:** | José Ignacio Rodríguez, Yerko Gallardo Miranda y Sebastián Rojas Araya |
| **Dataset:** | *E-Commerce Shipping Data* (Gopalani, 2021), 10.999 envíos |
| **Docente:** | J. P. Maidana |
| **Fecha:** | 28/10/2026 |
| **Repositorio GitHub:** | `https://github.com/joserodriguezc/grupo_1_estadistica_computacional` |

## Resumen ejecutivo

*(Pendiente.)*

## 1. Introducción

Una empresa de comercio electrónico de productos electrónicos registró 10.999 envíos (Gopalani, 2021), de los cuales el **59,67 %** llegó atrasado (IC de Wilson al 95 %: [58,75; 60,58]). El proyecto se organizó en tres fases que se apoyan una en otra.

**Sumativa 1 (S1): análisis exploratorio e inferencial.** Preguntó *qué características se asocian con el atraso y qué evidencia orienta una revisión operacional*. Encontró que los envíos atrasados pesan en promedio 896 g menos que los puntuales ($d_{av} = -0{,}57$) y reciben 13,1 unidades más de descuento ($d_{av} = 0{,}96$), mientras que la modalidad de envío no se asocia con el atraso ($p$ de Holm = 0,69). Recomendó auditar los 2.647 envíos con descuento mayor que 10, todos atrasados.

**Sumativa 2 (S2): validación por remuestreo y simulación.** Confirmó los intervalos y las decisiones de S1 con *bootstrap* y permutación ($B = 10.000$). Sus escenarios de sensibilidad mostraron que **el peso es la única asociación robusta**: la del descuento existe solo por el segmento con descuento mayor que 10, y el *jackknife* reveló que ese segmento coincide con los envíos 1 a 3.135 del archivo. La Formativa 2 ensayó una regresión logística con esos hallazgos: alcanzó un área bajo la curva ROC (AUC) de 0,714, pero de solo 0,52 en los envíos con descuento $\leq 10$.

**Sumativa 3 (S3): modelamiento.** Esta fase pasa de describir asociaciones a **clasificar el atraso**. Cada decisión se fundamenta en un resultado de S1 o de S2:

- manejo de datos faltantes, con imputación por regresión lineal múltiple y comparación de estrategias;
- tres modelos de regresión logística en el segmento con descuento $\leq 10$ (variables de S1 y S2, *stepwise* por AIC y reducido por BIC), con una regla para el segmento $> 10$, todo atrasado;
- estabilidad de los coeficientes por *bootstrap* y diagnóstico de supuestos;
- impacto de la estrategia de imputación sobre el modelo final.

La sección 2 describe la metodología integrada, la 3 presenta los resultados, la 4 los discute y la 5 formula las recomendaciones.

## 2. Metodología integrada

### 2.1 Datos, trazabilidad y punto de partida

**Datos y reproducibilidad.** Antes de usar el CSV original de S1, el notebook maestro verifica su huella SHA-256; el archivo se lee desde `sumativa_1/data/raw/`, sin copiarlo. Las cifras de S1, S2 y la Formativa 2 se leen desde sus tablas publicadas, sin recalcularse. Toda la aleatoriedad usa la semilla de S2 (`1505514103`), obtenida del pulso 1.053.589 del faro de aleatoriedad de la Universidad de Chile. De `SeedSequence(SEMILLA).spawn(10)` se derivan flujos independientes: los siete primeros son los de S2, el octavo es el de la Formativa 2, el noveno simula los faltantes y el décimo alimenta el *bootstrap* de S3.

**Partición común.** La partición 70/30, estratificada por el atraso, se define una sola vez sobre los 10.999 envíos: 7.699 de entrenamiento y 3.300 de prueba, ambos con 59,67 % de atraso. Es la misma de la Formativa 2. Todas las estrategias de imputación y todos los modelos usan esos mismos envíos, de modo que las diferencias entre resultados no dependen del azar de la partición. La preparación, el ajuste y las métricas usan funciones compartidas; con los datos completos, reproducen el AUC de la Formativa 2 (0,721).

**Punto de partida.** S1 registró **cero valores faltantes** en las 12 variables, por lo que el análisis de faltantes parte de un 0 % sin patrón. Las relaciones entre las variables numéricas son

débiles: ningún $|\rho|$ de Spearman supera 0,32 (figura 1). S2 distinguió dos grupos. El bloque peso–costo–compras previas–llamadas es **estable**: sus seis correlaciones excluyen el cero en los cuatro escenarios de sensibilidad. Las cuatro correlaciones del descuento son **inestables**: se anulan al retirar el segmento con descuento mayor que 10. La tabla 1 resume cómo estos hallazgos orientan cada decisión de S3.

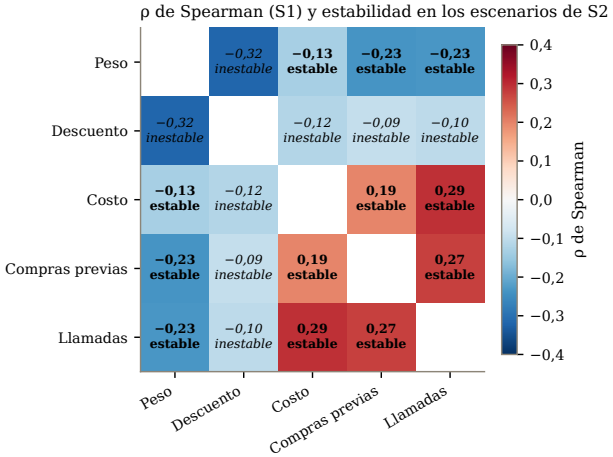



**Figura 1:** Correlaciones de Spearman entre las variables numéricas (S1) y su estabilidad en los cuatro escenarios de sensibilidad de S2. En negrita, las que excluyen el cero en todos los escenarios.

**Tabla 1:** Hallazgos de S1 y S2 que fundamentan las decisiones de S3.

| Hallazgo previo | Fuente | Decisión en S3 |
|---|---|---|
| Ningún valor faltante en 10.999 envíos | S1 | Simular faltantes con un mecanismo conocido para ejercitar la imputación |
| Matriz de Spearman entre variables numéricas | S1 | Origen de los predictores de cada regresión de imputación |
| Bloque peso–costo–compras–llamadas estable; descuento inestable | S2 | Priorizar predictores estables al imputar |
| Extremos IQR válidos; winsorizar no cambia nada y excluir cambia la población | S1, S2 | Conservar los outliers |
| Peso robusto; descuento dependiente del segmento $> 10$ (100 % atrasado); costo y compras débiles | S1, S2, F2 | Modelos en el segmento $\leq 10$ y regla para $> 10$; variables del modelo basado en S1 y S2 |
| Modalidad sin asociación (T01) | S1, S2 | Candidata solo para la selección automática |
| Llamadas y calificación posiblemente posteriores a la entrega | S1 | Excluidas como predictores del atraso |
| Envíos 1 a 3.135 todos atrasados | S2 | Excluir el identificador (fuga de información) |
| IC percentil y BCa validados con $B = 10.000$ | S2 | Mismo método para la estabilidad del modelo final |

## 2.2 Datos faltantes e imputación por regresión

*(Pendiente.)*

## 2.3 Regresión logística: preparación, selección y evaluación

**Preparación informada por S1 y S2.** Se utiliza el dataset elegido de imputación por regresión y la partición común de la sección 2.1. Se conservan los extremos: S1 los identificó como válidos y S2 mostró que winsorizar no alteraba las conclusiones. Las numéricas se estandarizan con media y desviación estándar (DE) del entrenamiento; las categóricas se codifican mediante indicadores, omitiendo el primer nivel ordenado como referencia. Se excluyen el identificador por la estructura detectada en S2, y llamadas y calificación por su posible registro posterior a la entrega.

**Tres especificaciones.** M1 incorpora peso, descuento, costo y compras previas, por las asociaciones de S1 y la continuidad con la Formativa 2; solo el peso fue robusto en todos los

escenarios de S2. M2 considera además importancia, bodega, modalidad y género mediante selección *stepwise* bidireccional desde el intercepto, con entrada $p < 0{,}05$ y salida $p > 0{,}10$. Se emplean pruebas de razón de verosimilitudes, con las categorías de cada variable tratadas como un bloque. M3 minimiza el criterio de información bayesiano (BIC) entre los 256 subconjuntos de las ocho variables, incluido el intercepto solo; se informa también el criterio de información de Akaike (AIC). Ambos procedimientos utilizan exclusivamente entrenamiento. Los ajustes se realizan por máxima verosimilitud; se reportan coeficientes y razones de odds (OR) con intervalos de confianza (IC) de Wald al 95 %.

**Evaluación y elección.** Con umbral fijo 0,5 se calculan matrices de confusión, exactitud, precisión, sensibilidad, F1 y especificidad, además de curvas ROC y AUC, en entrenamiento y prueba. La referencia es la clase mayoritaria del entrenamiento. Se consideran elegibles los modelos a no más de 0,005 de la mayor AUC de prueba y se elige el menor BIC; los empates se resuelven por número de parámetros y nombre. La tolerancia es práctica, no una prueba de equivalencia. Se examinan costos relativos de falsos negativos (FN) frente a falsos positivos (FP) de 1, 2 y 5, sin atribuirles valores monetarios reales.

**Alcance.** La evaluación es exploratoria: prueba participa en la elección y la imputación principal se ajustó antes de separar los conjuntos. Aunque no utiliza el atraso, incorpora información de los predictores de prueba. Además, llamadas interviene indirectamente en la imputación, por lo que su disponibilidad temporal debe revisarse antes de uso operacional. Los IC son condicionales al modelo y al dataset imputado; no incorporan incertidumbre por selección o imputación.

### 2.4 Estabilidad y diagnóstico

*(Pendiente.)*

## 3. Resultados integrados

### 3.1 Datos faltantes e imputación

*(Pendiente.)*

### 3.2 Modelos logísticos y desempeño

**Especificaciones y selección.** M1 y M3 coinciden en las cuatro variables numéricas. M2 añade importancia del producto, pero no modalidad, bodega ni género. La exclusión de modalidad es coherente con S1/S2. La tabla 2 muestra que la mejora de AUC de M2 es pequeña (0,0008), mientras BIC favorece M1/M3. Se elige **M1**, por desempate entre especificaciones idénticas. Esto favorece parsimonia dentro de la tolerancia adoptada, sin demostrar equivalencia predictiva.

**Tabla 2:** Selección de modelos: ajuste en entrenamiento y AUC en prueba.

| Modelo | Variables | Parámetros | AIC | BIC | AUC |
|---|---|---|---|---|---|
| M1 | Cuatro numéricas | 5 | 8.639,72 | 8.674,46 | 0,7154 |
| M2 | Numéricas + importancia | 7 | 8.629,41 | 8.678,05 | 0,7162 |
| M3 | Cuatro numéricas | 5 | 8.639,72 | 8.674,46 | 0,7154 |

**Coeficientes e interpretación.** La tabla 3 presenta los coeficientes estandarizados y los OR por DE (o por categoría), con IC de Wald. Todos los términos incluidos tienen $p < 0{,}001$; estos valores son condicionales a la selección. En M2, importancia baja y media presentan menores odds de atraso que importancia alta (OR 0,722 y 0,692). Son asociaciones ajustadas, no efectos causales.

En unidades del negocio, manteniendo los demás predictores constantes, M1 estima un OR de **0,835 por 1.000 g** (IC 95 %: [0,804; 0,866]), equivalente a odds de atraso 16,5 % menores; por **10 unidades de descuento**, las odds se multiplican por **2,756** ([2,520; 3,013]). Por 10 USD de costo, el OR es 0,977 ([0,965; 0,988]); por una compra previa adicional, 0,927 ([0,893; 0,962]).

**Tabla 3:** Coeficientes y OR de los tres modelos. M1 y M3 tienen ajustes idénticos.

| Modelo | Predictor | $\beta$ | OR | IC 95 % del OR |
|---|---|---|---|---|
| M1/M3 | Peso | -0,285 | 0,752 | [0,710; 0,798] |
| M1/M3 | Descuento | 1,575 | 4,829 | [4,204; 5,547] |
| M1/M3 | Costo | -0,108 | 0,897 | [0,850; 0,947] |
| M1/M3 | Compras previas | -0,110 | 0,896 | [0,849; 0,945] |
| M2 | Peso | -0,293 | 0,746 | [0,703; 0,791] |
| M2 | Descuento | 1,574 | 4,824 | [4,198; 5,542] |
| M2 | Costo | -0,108 | 0,897 | [0,850; 0,947] |
| M2 | Compras previas | -0,115 | 0,892 | [0,845; 0,941] |
| M2 | Importancia baja / alta | -0,325 | 0,722 | [0,597; 0,875] |
| M2 | Importancia media / alta | -0,369 | 0,692 | [0,571; 0,838] |

Estas lecturas describen el modelo especificado, no cambios porcentuales de probabilidad; su interpretación definitiva requiere completar estabilidad y diagnóstico.

**Desempeño.** La tabla 4 y la figura 2 comparan entrenamiento y prueba. M1 obtiene AUC 0,7154 y exactitud 63,03 % en prueba. La clase mayoritaria alcanza exactitud 59,67 % y F1 74,74 %, superior al F1 de M1, pero especificidad cero: clasifica todos los envíos como atrasados. Por ello, M1 no mejora todas las métricas de la referencia.

**Tabla 4:** Métricas con umbral 0,5. Excepto AUC, valores porcentuales; entrenamiento: 7.699 envíos, prueba: 3.300.

| Modelo | Conjunto | Exact. | Prec. | Sens. | F1 | Espec. | AUC |
|---|---|---|---|---|---|---|---|
| M1 | Entren. | 63,14 | 69,57 | 67,94 | 68,74 | 56,04 | 0,7112 |
| M1 | Prueba | 63,03 | 69,31 | 68,26 | 68,78 | 55,30 | 0,7154 |
| M2 | Entren. | 63,33 | 69,79 | 67,98 | 68,87 | 56,46 | 0,7137 |
| M2 | Prueba | 63,45 | 69,88 | 68,11 | 68,98 | 56,57 | 0,7162 |
| M3 | Entren. | 63,14 | 69,57 | 67,94 | 68,74 | 56,04 | 0,7112 |
| M3 | Prueba | 63,03 | 69,31 | 68,26 | 68,78 | 55,30 | 0,7154 |

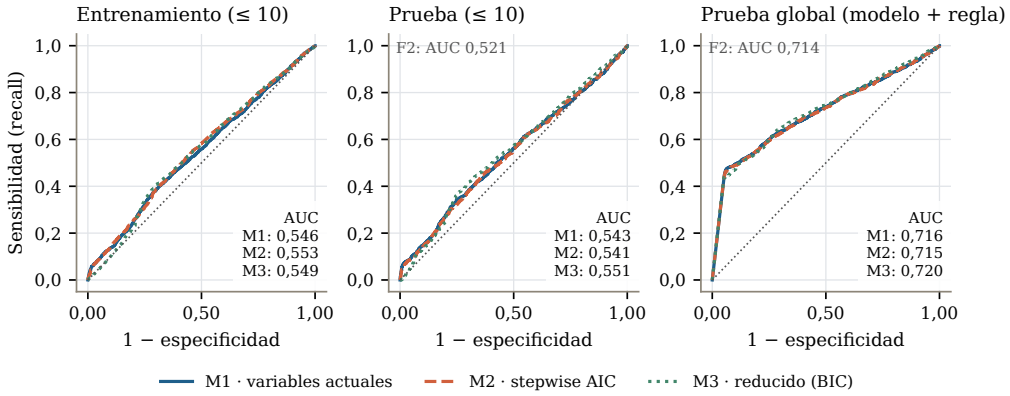



**Figura 2:** Curvas ROC en entrenamiento y prueba. Las curvas M1 y M3 coinciden; la diagonal representa ausencia de discriminación.

En prueba, M1 identifica 1.344 atrasos, omite 625 y genera 595 falsas alertas; reconoce correctamente 736 envíos puntuales. M2 reduce las falsas alertas a 578, pero omite 628 atrasos. El costo de M1 menos el de M2 es $17 - 3r$, donde $r$ es el costo relativo FN:FP: M2 tiene menor costo en los escenarios $r = 1, 2, 5$, y M1 lo tendría para $r > 17/3$. Por tanto, la elección por parsimonia no garantiza menor costo operacional. Las matrices completas de ambos conjuntos se muestran en la figura 3.

**Trazabilidad:** tablas exportadas por el notebook en `sumativa_3/outputs/tablas/`: `modelos_resumen.csv`, `modelos_coeficientes_or.csv`, `modelos_metricas.csv` y `modelos_seleccion.csv`.

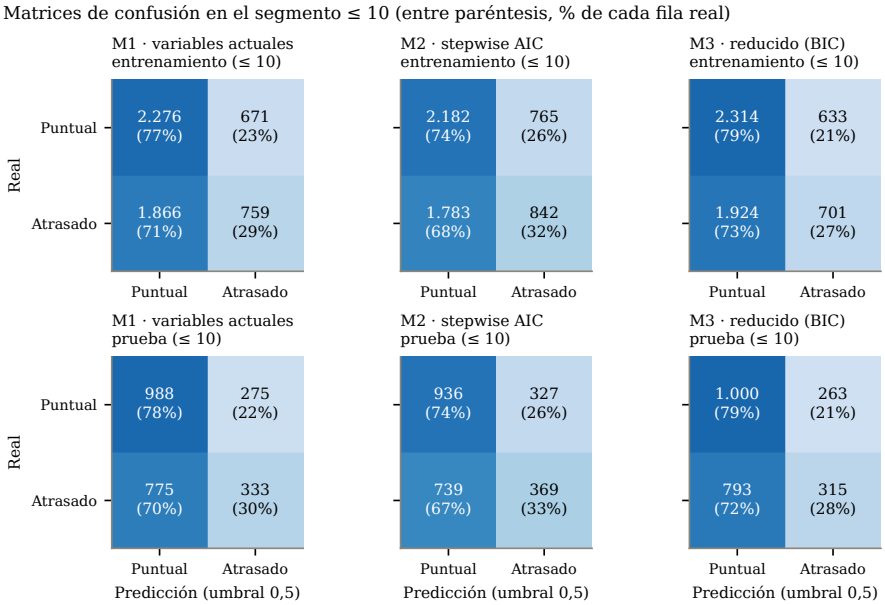



**Figura 3:** Matrices de confusión de los tres modelos, con clase 1 = atraso y clase 0 = entrega puntual. Filas: clase real; columnas: predicción.

### 3.3 Estabilidad del modelo final

*(Pendiente.)*

### 3.4 Diagnóstico del modelo final

*(Pendiente.)*

### 3.5 Impacto de la estrategia de imputación

*(Pendiente.)*

## 4. Discusión

*(Pendiente.)*

## 5. Conclusiones y recomendaciones

*(Pendiente.)*

## Referencias


- Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Gopalani, P. (2021). *E-Commerce Shipping Data*, versión 1. Kaggle.
- Hosmer, D. W., Lemeshow, S. y Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.ª ed.). Wiley.
- Little, R. J. A. y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.