

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Cierre y Comunicación del Proyecto

Informe final integrado · 60 %

Título del proyecto:	Factores asociados al atraso en envíos de comercio electrónico: del análisis exploratorio a la clasificación
Integrantes:	José Ignacio Rodríguez, Yerko Gallardo Miranda y Sebastián Rojas Araya
Dataset:	*E-Commerce Shipping Data* (Gopalani, 2021), 10.999 envíos
Docente:	J. P. Maidana
Fecha:	28/10/2026
Repositorio GitHub:	`https://github.com/joserodriguezc/grupo_1_estadistica_computacional`

Resumen ejecutivo

(Pendiente.)

1. Introducción

Una empresa de comercio electrónico de productos electrónicos registró 10.999 envíos (Gopalani, 2021), de los cuales el **59,67 %** llegó atrasado (IC de Wilson al 95 %: [58,75; 60,58]). El proyecto se organizó en tres fases que se apoyan una en otra.

Sumativa 1 (S1): análisis exploratorio e inferencial. Preguntó *qué características se asocian con el atraso y qué evidencia orienta una revisión operacional*. Encontró que los envíos atrasados pesan en promedio 896 g menos que los puntuales ($d_{av} = -0{,}57$) y reciben 13,1 unidades más de descuento ($d_{av} = 0{,}96$), mientras que la modalidad de envío no se asocia con el atraso (p de Holm = 0,69). Recomendó auditar los 2.647 envíos con descuento mayor que 10, todos atrasados.

Sumativa 2 (S2): validación por remuestreo y simulación. Confirmó los intervalos y las decisiones de S1 con *bootstrap* y permutación ($B = 10.000$). Sus escenarios de sensibilidad mostraron que **el peso es la única asociación robusta**: la del descuento existe solo por el segmento con descuento mayor que 10, y el *jackknife* reveló que ese segmento coincide con los envíos 1 a 3.135 del archivo. La Formativa 2 ensayó una regresión logística con esos hallazgos: alcanzó un área bajo la curva ROC (AUC) de 0,714, pero de solo 0,52 en los envíos con descuento ≤ 10.

Sumativa 3 (S3): modelamiento. Esta fase pasa de describir asociaciones a **clasificar el atraso**. Cada decisión se fundamenta en un resultado de S1 o de S2:

- manejo de datos faltantes, con imputación por regresión lineal múltiple y comparación de estrategias;
- tres modelos de regresión logística, con variables elegidas por S1 y S2, por selección *stepwise* y por criterios de información;
- estabilidad de los coeficientes por *bootstrap* y diagnóstico de supuestos;
- impacto de la estrategia de imputación sobre el modelo final.

La sección 2 describe la metodología integrada, la 3 presenta los resultados, la 4 los discute y la 5 formula las recomendaciones.

2. Metodología integrada

2.1 Datos, trazabilidad y punto de partida

Datos y reproducibilidad. Antes de usar el CSV original de S1, el notebook maestro verifica su huella SHA-256; el archivo se lee desde `sumativa_1/data/raw/`, sin copiarlo. Las cifras de S1, S2 y la Formativa 2 se leen desde sus tablas publicadas, sin recalcularse. Toda la aleatoriedad usa la semilla de S2 (`1505514103`), obtenida del pulso 1.053.589 del faro de aleatoriedad de la Universidad de Chile. De `SeedSequence(SEMILLA).spawn(10)` se derivan flujos independientes: los siete primeros son los de S2, el octavo es el de la Formativa 2, el noveno simula los faltantes y el décimo alimenta el *bootstrap* de S3.

Partición común. La partición 70/30, estratificada por el atraso, se define una sola vez sobre los 10.999 envíos: 7.699 de entrenamiento y 3.300 de prueba, ambos con 59,67 % de atraso. Es la misma de la Formativa 2. Todas las estrategias de imputación y todos los modelos usan esos mismos envíos, de modo que las diferencias entre resultados no dependen del azar de la partición. La preparación, el ajuste y las métricas usan funciones compartidas; con los datos completos, reproducen el AUC de la Formativa 2 (0,721).

Punto de partida. S1 registró **cero valores faltantes** en las 12 variables, por lo que el análisis de faltantes parte de un 0 % sin patrón. Las relaciones entre las variables numéricas son

débiles: ningún $|\rho|$ de Spearman supera 0,32 (figura 1). S2 distinguió dos grupos. El bloque peso–costo–compras previas–llamadas es **estable**: sus seis correlaciones excluyen el cero en los cuatro escenarios de sensibilidad. Las cuatro correlaciones del descuento son **inestables**: se anulan al retirar el segmento con descuento mayor que 10. La tabla 1 resume cómo estos hallazgos orientan cada decisión de S3.

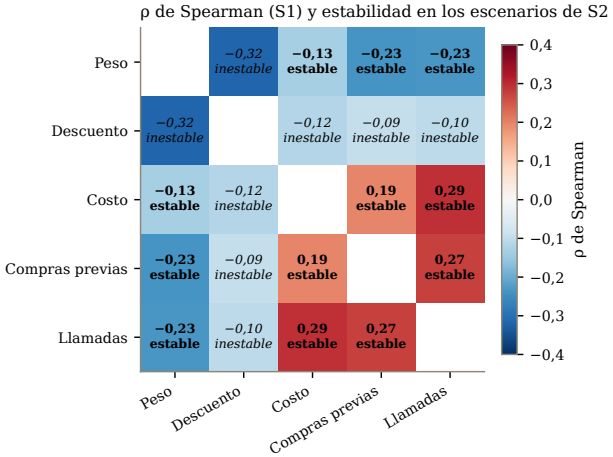


Figura 1: Correlaciones de Spearman entre las variables numéricas (S1) y su estabilidad en los cuatro escenarios de sensibilidad de S2. En negrita, las que excluyen el cero en todos los escenarios.

Tabla 1: Hallazgos de S1 y S2 que fundamentan las decisiones de S3.

Hallazgo previo	Fuente	Decisión en S3
Ningún valor faltante en 10.999 envíos	S1	Simular faltantes con un mecanismo conocido para ejercitar la imputación
Matriz de Spearman entre variables numéricas	S1	Origen de los predictores de cada regresión de imputación
Bloque peso–costo–compras–llamadas estable; descuento inestable	S2	Priorizar predictores estables al imputar
Extremos IQR válidos; winsorizar no cambia nada y excluir cambia la población	S1, S2	Conservar los outliers
Peso robusto; descuento dependiente del segmento > 10; costo y compras débiles	S1, S2	Variables del modelo basado en S1 y S2; diagnóstico de linealidad del descuento
Modalidad sin asociación (T01)	S1, S2	Candidata solo para la selección automática
Llamadas y calificación posiblemente posteriores a la entrega	S1	Excluidas como predictores del atraso
Envíos 1 a 3.135 todos atrasados	S2	Excluir el identificador (fuga de información)
IC percentil y BCa validados con $B = 10.000$	S2	Mismo método para la estabilidad del modelo final

2.2 Datos faltantes e imputación por regresión

(Pendiente.)

2.3 Regresión logística: preparación, selección y evaluación

(Pendiente.)

2.4 Estabilidad y diagnóstico

(Pendiente.)

3. Resultados integrados

3.1 Datos faltantes e imputación

(Pendiente.)

3.2 Modelos logísticos y desempeño

(Pendiente.)

3.3 Estabilidad del modelo final

(Pendiente.)

3.4 Diagnóstico del modelo final

(Pendiente.)

3.5 Impacto de la estrategia de imputación

(Pendiente.)

4. Discusión

(Pendiente.)

5. Conclusiones y recomendaciones

(Pendiente.)

Referencias

- Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Gopalani, P. (2021). *E-Commerce Shipping Data*, versión 1. Kaggle.
- Hosmer, D. W., Lemeshow, S. y Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.ª ed.). Wiley.
- Little, R. J. A. y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.